

# 中国研究生网络安全创新大赛

## 作品报告

作品名称: VoiceGuard: 基于数据毒化的高鲁棒性防克隆语音  
保护系统

提交日期: 2025 年 9 月 20 日

## 填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。
2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。
3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。一经发现，取消作品参赛资格。

## 作品简介

作品名称：VoiceGuard：基于数据毒化的高鲁棒性防克隆语音保护系统

参赛队伍名称：防克隆哨兵

参赛成员：米逸凡（队长），姜超，汤先宁

作品简介：

随着智能设备的普及和语音识别技术的飞速发展，个人隐私泄露的风险也日益加剧。语音交互成为现代社会中常见的人机沟通方式，然而，语音克隆技术的广泛应用也带来了隐私安全问题。特别是近年来，基于端到端微调的语音克隆技术取得了显著进展，其典型代表如Tacotron、FastSpeech等模型，通过少量目标说话人的语音样本即可高效微调预训练声学模型，实现高保真、高自然度的语音复刻。由于其强大的泛化能力和低样本依赖性，该技术也为恶意攻击者提供了低成本、高精度的语音伪造手段，极大增加了身份冒用、社会工程攻击和深度伪造等安全风险。VoiceGuard旨在应对这一挑战，通过基于对抗样本和音色音质的对抗扰动技术和数据毒化技术，构建一个针对基于微调的端到端语音克隆的隐私保护系统，有效阻止语音数据被不当克隆和滥用。

本作品创新性地运用对抗扰动技术，生成有效的、不可察觉的音频扰动，能够对当前多种最先进的语音合成系统产生干扰，具备良好的迁移性。通过心理声学模型等方法对扰动进行约束，能够在保护用户隐私的同时不影响用户的正常沟通。通过对现有技术的改进，VoiceGuard不仅提高了对抗扰动的实时性和通用性，还显著增强了系统的防护能力和实用性，提供了一种高效的隐私保护解决方案。

# 目 录

|                             |    |
|-----------------------------|----|
| 摘要 .....                    | 1  |
| 第一章 作品概述 .....              | 2  |
| 1.1 作品背景与意义 .....           | 2  |
| 1.2 相关工作 .....              | 5  |
| 1.2.1 语音合成 .....            | 5  |
| 1.2.2 语音隐私保护 .....          | 7  |
| 1.3 作品特色描述 .....            | 8  |
| 1.3.1 面向新兴语音克隆攻击的有效防御 ..... | 9  |
| 1.3.2 基于攻击链协同破坏的安全机制 .....  | 9  |
| 1.3.3 感知无损的音频扰动优化 .....     | 9  |
| 1.4 作品前景分析 .....            | 10 |
| 第二章 相关技术介绍 .....            | 12 |
| 2.1 语音合成 .....              | 12 |
| 2.1.1 深度神经网络 .....          | 13 |
| 2.1.2 传统语音合成 .....          | 15 |
| 2.1.3 现代语音合成 .....          | 15 |
| 2.2 对抗攻击和防御 .....           | 19 |
| 2.2.1 对抗攻击 .....            | 19 |
| 2.2.2 对抗防御 .....            | 22 |
| 2.3 数据毒化 .....              | 23 |
| 第三章 作品设计与实现 .....           | 25 |
| 3.1 系统设计目标 .....            | 25 |
| 3.2 系统总体设计 .....            | 25 |
| 3.2.1 系统架构设计 .....          | 26 |
| 3.2.2 系统工作流程 .....          | 27 |
| 3.2.3 系统功能模块 .....          | 30 |
| 3.3 系统核心技术 .....            | 31 |
| 3.3.1 核心算法流程 .....          | 32 |
| 3.3.2 端到端的语音保护 .....        | 33 |
| 3.4 系统功能实现 .....            | 37 |
| 3.4.1 音色保护模块 .....          | 37 |
| 3.4.2 发音保护模块 .....          | 38 |
| 3.4.3 感知优化模块 .....          | 38 |
| 3.4.4 扰动约束模块 .....          | 39 |
| 3.5 系统应用实现 .....            | 39 |
| 3.5.1 音频保护模块 .....          | 41 |
| 3.5.2 保护效果展示模块 .....        | 42 |
| 3.5.3 历史记录查看模块 .....        | 43 |

|                              |    |
|------------------------------|----|
| 第四章 作品测试与分析 .....            | 44 |
| 4.1 测试设置 .....               | 44 |
| 4.1.1 数据集 .....              | 44 |
| 4.1.2 测试环境 .....             | 45 |
| 4.1.3 目标场景 .....             | 45 |
| 4.1.4 评价指标 .....             | 47 |
| 4.2 测试方案 .....               | 48 |
| 4.2.1 技术性能测试 .....           | 48 |
| 4.2.2 实际应用测试 .....           | 49 |
| 4.3 性能测试结果与分析 .....          | 49 |
| 4.3.1 针对不同 ASR 系统的防护性能 ..... | 49 |
| 4.3.2 多说话人和多语言场景下的防护性能 ..... | 50 |
| 4.3.3 有效性和迁移性 .....          | 51 |
| 4.3.4 感知分析 .....             | 53 |
| 4.3.5 消融实验结果分析 .....         | 53 |
| 4.3.6 鲁棒性测试结果分析 .....        | 54 |
| 4.4 应用测试结果与分析 .....          | 56 |
| 4.4.1 基本功能测试 .....           | 56 |
| 4.4.2 历史记录功能测试 .....         | 59 |
| 4.4.3 长语音测试 .....            | 60 |
| 4.4.4 中文音频测试 .....           | 61 |
| 第五章 创新性说明 .....              | 62 |
| 第六章 总结 .....                 | 64 |
| 参考文献 .....                   | 66 |

## 摘要

语音合成技术为人们的生活带来了巨大的便利，然而，高度逼真的深度伪造音频的广泛使用也引发了诸多潜在危害。恶意攻击者可能未经授权收集受害者的语音数据，并通过克隆相似的声音进行非法利用，例如电信诈骗。现有的防御方法无法有效防止这些深度伪造音频的滥用，且容易受到鲁棒性训练技术的规避。因此，迫切需要一种更加高效并且鲁棒的数据保护方法来应对这一挑战。同时，研究和工业界涌现了越来越多的**基于微调的端到端语音合成系统**，能够使用无对应文本的音频数据，仅仅经过微调就能克隆出高质量的合成语音，对个人声纹隐私造成极大威胁。

为此，本作品针对这种基于微调的端到端语音克隆场景，实现了一个名为「**VoiceGuard**」的主动语音防克隆防御框架。基于数据毒化技术，使用对抗样本诱导语音识别模型错误地识别文本，从而打破文本-发音的对齐，针对基于微调的端到端语音合成系统进行防御，有效防止个人语音数据未经授权的使用。

「**VoiceGuard**」的创新之处在于：（1）提出更现实且具挑战性的**基于微调的端到端的语音合成场景**，并设计一种基于数据毒化的主动防御模块VoiceGuard以保护个体敏感声纹信息；（2）从**音色与发音双维度**实现防御性波形干扰：通过编码器集成与特征提取器构建特征目标函数破坏音色；利用针对ASR系统的对抗样本导致文本误识别，进而影响发音学习；（3）引入**心理声学模型和 $\mathcal{L}_2$ 约束目标**，降低保护后音频中扰动被人耳的感知程度，提高音频的保真度。

为了全面评估本作品提出的技术，在多个先进的模型和数据集上进行了广泛的实验。实验结果表明，本作品的语音保护技术在有效性和迁移性方面达到了当前最先进的水平，并且对高级自适应攻击具有极高的鲁棒性。此外，本作品提出的语音保护算法在实际测试中展现了实时处理能力，验证了其在真实场景中的可行性与实用性。

# 第一章 作品概述

本章首先描述了本作品考虑的现实背景，介绍本作品面向的现实安全问题以及解决思路。1.2 节梳理了国内外语音合成与隐私保护技术的研究进展，对具有参考意义的研究进行简单的介绍，同时指出现有技术的不足。1.3 节将提出作品的改进方法和综合解决方案，说明本作品的特色与优势。最后，1.4 节将描述自身应用前景，体现作品的实际价值。

## 1.1 作品背景与意义

近年来，深度神经网络（Deep Neural Network, DNN）在计算资源指数级增长的支撑下，逐步突破多重技术瓶颈。2012年，AlexNet模型<sup>[1]</sup>通过引入多层卷积神经网络（Convolutional Neural Network, CNN）架构<sup>[2]</sup>，在大规模数据集ImageNet<sup>[3]</sup>的视觉识别挑战赛中首次超越人类识别准确率，这一里程碑事件不仅验证了深度学习的特征抽象能力，更开启了计算机视觉领域的黄金十年。2015年，ResNet模型<sup>[4]</sup>创新性地提出残差连接机制，成功攻克了深层网络梯度消失难题，将神经网络深度拓展至千层量级，为后续复杂生成任务的建模奠定了结构基础。2017 年，Transformer模型<sup>[5]</sup>通过自注意力机制重构序列建模范式，其全局依赖捕获能力直接推动了生成式技术的质变跃迁。值得关注的是，OpenAI通过系统性研究提出的扩展法则（Scaling Law）<sup>[6]</sup>，揭示了大语言模型（Large Language Model, LLM）在庞大模型参数量和海量训练数据的基础上所展现出的上下文学习能力、指令跟随等智能特质。至2022年底，ChatGPT凭借类人的交互能力引发全球AI技术革命，而2025年DeepSeek-R1<sup>[7]</sup>作为首款具备显性思维链路的推理模型，进一步拓展了认知智能的边界。

在生成式人工智能的诸多技术任务中，语音合成（Speech Synthesis）作为关键分支，也正经历一场由数据驱动和算法创新共同推动的跨越式发展。其技术演进脉络清晰：从早期基于隐马尔可夫模型（HMM）的参数合成方法<sup>[8]</sup>，发展到如今占据主流的端到端深度神经网络架构。当前，诸如VITS<sup>[9]</sup>、StyleTTS2<sup>[10]</sup>、FishSpeech<sup>[11]</sup>等先进模型，凭借生成对抗网络、流模型和扩散模型等机制，显著提升了合成语音的表现力与自然度，使其在主观听觉评测中已逼近甚至部分超越人类发音水平。这些现代系统

通常建立在自监督学习范式之上，能够从百万小时级的大规模多语言语音数据中自动化地学习并解耦出语音中的多种要素，包括细粒度的韵律结构、音素级别的内容表征以及跨说话人的音色特性。尤为引人注目的是，零样本语音克隆技术已实现重大突破，仅需5秒的目标说话人音频样本即可完成高保真的音色迁移与语音生成<sup>[12]</sup>。这一技术飞跃不仅极大地推动了智能客服、虚拟数字人、有声读物、无障碍阅读等应用场景的体验升级，更催生了以语音合成技术为核心的新型内容创作与工业化生产模式，对媒体制作、娱乐产业和人机交互等领域产生深远影响。

然而，技术红利伴随的伦理风险已引发全球关注。语音合成技术早期主要应用于提升信息传递效率（如智能导航播报、个性化语音助手等），但被滥用时，会带来严重的风险。声音克隆技术潜在的安全风险主要包括以下几个方面：

**1. 声音欺骗和身份伪造：**声音克隆技术可以被用于制作出与真人声音高度相似的语音，从而进行身份欺骗和语音钓鱼等违法犯罪活动。犯罪分子已利用该技术从事非法活动，如语音钓鱼和欺诈性冒充。例如，在一场全球虚拟会议中，诈骗犯合成了一位英国高管的语音，向香港一家公司员工发出大额资金转账指令，导致企业遭受巨额财产损失<sup>[13]</sup>。同样，东南亚诈骗集团模仿受害者亲友的声音，实施网络钓鱼和电话诈骗，误导全球众多受害者上当<sup>[14]</sup>。

**2. 隐私泄露和信息安全威胁：**语音合成模型的训练依赖大量真人语音数据，如果这些数据被非法获取或泄露，将严重侵犯个人隐私。同时，克隆出的语音也可能被用于窃取个人或企业敏感信息。在一起典型案例中，朝鲜黑客利用声音克隆技术合成美国军工公司高管的语音，向员工下达指令，骗取公司商业机密和核心技术数据，从而加剧了地缘政治紧张局势<sup>[15]</sup>。

**3. 虚假信息 and 舆论操纵：**声音克隆技术可能被滥用于制造虚假音频信息，误导公众舆论，散布不实谣言，影响社会稳定。在美国总统竞选期间，有人合成候选人的语音，发布虚假的竞选承诺，误导选民和操纵选举结果<sup>[16]</sup>。同样，在俄乌冲突中，有恐怖分子组织克隆了对方军队领导人的声音，发布虚假的作战指令，企图制造军事混乱和伤害<sup>[17]</sup>。

**4. 知识产权和版权侵犯：**未经许可擅自克隆他人声音，可能会构成对个人肖像权和知识产权的侵犯。国内一名犯罪分子非法获取了某些知名女明星的语音数据，克

隆出其声音并使用换脸及对口型技术，非法牟利超百万元，严重侵犯了其个人隐私和肖像权<sup>[18]</sup>。成都某文化公司未经许可，克隆了著名演员的声音，在电影和游戏中使用，引发了版权纠纷和赔偿诉讼<sup>[19]</sup>。

美国德克萨斯州著名配音艺术家和演员蒂姆·海勒从事卡通人物配音、有声读物、纪录片、视频游戏以及电影预告片等工作，当他首次听到自己的语音克隆时，震惊地表示“听到的声音如此准确，以至于我惊掉了下巴……这令人震惊”<sup>[20]</sup>。



图1-1 语音克隆犯罪实例<sup>[20]</sup>

这些案例凸显了语音合成技术的伦理隐患，面对深度伪造技术带来的身份认证危机，现有防护体系呈现显著滞后性，一种更加强大、通用和鲁棒的防克隆语音保护算法仍待研究。针对上述问题，本作品提出了VoiceGuard——一种基于数据毒化的高鲁棒性防克隆语音保护系统。本作品通过将对扰动技术和数据毒化技术应用于语音隐私保护，构建了双路协同攻击目标函数，从“音色-发音”两个核心维度同时破坏克隆效果，实现了对合成语音质量的联合降质，使得语音数据能够在多种不同的基于微调的端到端语音合成系统上展现出高效的防御性能，以满足实际场景中用户对个人敏感声纹信息的保护需求。此外，作品还采用了心理声学模型和范数约束降低人耳对抗扰动的感知。

## 1.2 相关工作

### 1.2.1 语音合成

1. 在语音合成技术演进历程中，传统方法奠定了重要基础。

1980年，Klatt等人<sup>[21]</sup>提出了基于共振峰合成的KlattTalk系统，开创了规则式语音合成先河。基于规则的合成系统采用声学-发音理论建模，通过调整共振峰频率、带宽等40多个参数模拟声道特性，但需手工编写复杂规则库。

2002年，Tokuda等人<sup>[22]</sup>将隐马尔可夫模型（Hidden Markov Model, HMM）引入语音合成，推出HTS工具包，通过隐马尔可夫模型对频谱、基频、时长进行联合建模，典型系统如HTS工具包支持基于上下文相关音素的参数生成，但受限于高斯假设常产生“嗡嗡声”失真。

2003年，Black等人<sup>[23]</sup>的Festival团队完善了单元选择拼接框架，支持多语言语音生成。通过Viterbi算法选择最优语音片段，虽提升自然度却面临存储成本高（需GB级语料）、跨语境拼接生硬等问题。这些传统方法为现代神经波形合成提供了频谱建模与参数控制的理论框架。

2. 现代语音合成模型主要聚焦于端到端结构。

2018年，Tacotron系列<sup>[24]-[25]</sup>的提出标志着端到端语音合成模型的突破。Tacotron直接将文本映射到梅尔频谱图（Mel-spectrogram），再通过声码器，例如Griffin-Lim技术，生成语音波形图，实现端到端的语音合成。

2019年起，FastSpeech系列<sup>[26]-[27]</sup>克服了自回归模型在生成过程中速度较慢的问题，通过非自回归的方式生成语音特征，并结合并行计算大幅提升了合成速度，同时保证了高质量的语音输出。

2021年，VITS<sup>[9]</sup>结合了变分推理和生成对抗网络，为语音合成领域带来了显著的性能提升和更高的自然度。此外，VITS使用了一种流式生成的方式，通过将声码器HiFiGAN<sup>[28]</sup>嵌入进语音合成系统训练，实现将文本输入直接映射到语音波形输出。

在多模态融合方向，研究者们正突破传统单一文本输入的桎梏，致力于开发以视觉信息为驱动源的跨模态语音生成系统。这包括：基于高精度人脸关键点检测与3D面部重建技术驱动语音合成，实现说话人面部表情与语音的精确同步；利用卡通形象或虚拟角色的骨骼绑定与动作数据，实时生成符合其动作和表情的语音；以及高度优

化的视频唇形同步技术，确保生成的语音与视频中人物的口型在时间和形态上达到高度一致。这些技术的融合，为3D虚拟人、数字主播、游戏角色、影视后期配音等场景提供了语音与形象无缝联动的解决方案，极大地增强了沉浸感和表现力。

尤其值得关注的是，开源大语言模型的爆发式发展，为语音合成领域注入了强大的语义理解与生成能力，催生了革命性的语义级语音控制技术。用户不再需要直接操控复杂的声学参数，而是可以通过自然语言描述，直接、精准地定制语音的深层属性。例如，用户只需输入“请用更加兴奋和充满期待的语气，语速稍快，带一点轻微的南方口音”这样的指令，系统便能理解并生成符合要求的语音。这涵盖了情感强度与类型（如“加强欢快语气”、“加入一丝忧伤”）、地域方言特征（如“加入川渝地区口音”、“模仿粤语腔调普通话”）、说话风格（如“正式演讲风格”、“朋友间闲聊语气”）、甚至特定角色音色（如“模仿某位名人”）等复杂维度。代表性工作如阿里的CosyVoice<sup>[30]</sup>，不仅支持通过提示词灵活定制音色和风格，更实现了上百种预置音色间的毫秒级实时转换，展现了强大的可控性与效率；而Fish-Audio团队的FishSpeech<sup>[11]</sup>，则以其高效的端到端架构，显著提升了高质量音频的生成速度。




图1-2 语音合成技术发展历程图<sup>[29]</sup>

同时，在工业界，越来越多的端到端语音合成模型不断涌现，进一步加剧了个人语音信息被滥用的情况。下面给出两个实际案例，说明基于微调的端到端语音防克隆的重要性。

### (1) 字节跳动API案例

以字节跳动语音克隆产品为例，第三方用户通过API将音频上传至公司服务器基础设施：首先通过ASR系统将输入音频转写为文本，随后将转写文本与音频信息共同

输入TTS模型进行声音训练，从而使用训练后的音色合成目标文本。这种基于商业API的语音合成方法同样符合端到端场景特征。

## (2) 开源WebUI操作案例

GPT-SoVITS<sup>[65]</sup>作为开源零样本语音克隆模型，支持通过少量样本微调提升声音相似度。该项目提供基于WebUI的微调 workflow：首先利用ASR系统（即OpenAI的Whisper<sup>[74]</sup>）获取对应文本，随后基于文本与音频进行微调，这也满足端到端场景需求。

从这两个案例可见，端到端语音合成在现实应用中已十分普遍。此外，基于ASR的工作流正逐渐成为主流，这些流程通常运行在模型或服务器后端，终端用户无法直接访问。

### 1.2.2 语音隐私保护

现阶段针对语音合成的语音隐私保护技术可以分为基于检测的防御和基于数据的防御。基于检测的防御通常使用辅助信息或模型帮助判断一段音频是否由AI生成。基于数据的防御旨在从原始音频数据的层面防止说话人的信息被克隆。本作品主要考虑数据防御层面的语音防克隆技术，目前的研究主要集中在以下两种类型：

#### 1. 基于对抗样本(Adversarial Examples, AEs)的保护技术

研究人员通过使用对抗样本攻击在原始的音频上添加一些精心制作的不可感知的扰动，从而实现克隆出来的音频与原说话人不相似。2021年，Huang等人<sup>[31]</sup>聚焦于语音转换（Voice Conversion）技术存在的安全问题，通过对抗样本的方式提出了AttackVC语音保护技术，使得原始说话人和目标说话人的音色嵌入相近，从而使得被保护的音频无法正确进行语音转换得到原始说话人的音色。2023年，Wang等人<sup>[32]</sup>针对语音合成技术的深度伪造攻击问题，提出VSMask防御方案。该技术通过实时预测性扰动动态干扰攻击模型的输入，使合成语音的原始音色特征被破坏，同时支持流式语音的低延迟保护，可有效抵御多种主流合成模型的攻击。2023年，Yu等人<sup>[33]</sup>进一步针对语音合成领域的隐私安全，提出了一种名为AntiFake的主动防御框架。AntiFake使用对抗样本防止零样本合成出与输入音频相似的音色，区别于AttackVC和VSMask技术的随机选取性别相对的目标音频，AntiFake构建了一个说话人数据库，针对每一条待保护的音频需要从数据库中选取音色特征差别最大的音频作为目标音频用于优

化。同时，AntiFake使用编码器集群的方式提升了被保护音频在不同语音合成模型之前的迁移性。

## 2. 基于不可学习样本(Unlearnable Examples, UEs)的保护技术

不可学习样本(Unlearnable Examples, UEs)是一种数据隐私保护技术，保护方会通过误差最小化的方式产生扰动从而将原始的训练数据集转变为不可学习的样本，而模型在不可学习样本上训练后，在训练集上表现良好，而在测试集上标签较差。2021年，Huang<sup>[64]</sup>等人引入了不可学习样本这一概念，并提出了一种双极误差最小化的扰动产生方式，如公式（1-1）所示。

$$\operatorname{argmin}_{\theta} E_{(x,y) \in D} \min_{\delta} L(f(x + \delta), y), \quad (1-1)$$

其中， $(x,y)$ 为训练数据集 $D$ 中的图像和标签对。 $\delta$ 为用于保护的扰动，其需要满足 $\|\delta\|_p \leq \epsilon$ ，即使用 $L_p$ 范数将扰动的大小限制在 $\epsilon$ -球内，保证被保护数据与原始数据无明显区别。

公式（1-1）展示了一个双极优化问题，外层最小化替代模型 $f$ 的参数，内层最小化扰动大小。不可学习样本的本质在于使用扰动将模型的目标函数最小化，从而使得真正模型训练时，由于损失值较低，导致“没有信息”去学习，所以将这种保护后的数据称为不可学习样本。这类不可学习样本的优化方式与目标函数有关，所以针对不同的任务，只需要替换适合的目标函数。不可学习样本的目的在于产生扰动使得隐私数据无法被模型学习到，在语音合成领域，基于不可学习样本的方式对语音数据进行保护能够有效防止恶意语音合成对声音隐私信息的未经授权地利用。

然而，之前的研究主要聚焦于针对零样本克隆模型实现保护，并未考虑基于微调的语音合成模型这一策略，所以本作品希望实现的是能够对音频的音色和可用性实现保护，并能够有效抵抗零样本和基于微调的语音合成。

## 1.3 作品特色描述

本作品针对基于微调的端到端语音防克隆场景中对防御有效性、语音保护鲁棒性与语音感知质量的综合需求，实现了一个名为VoiceGuard的主动语音防克隆防御框架。通过添加精心设计的损失函数和优化目标，在保证高保真语音体验的同时，有效抵御语音克隆攻击对用户声纹身份的窃取与滥用。本节将会简要介绍作品具有的一些优良

特性以及实现思路。

### 1.3.1 面向新兴语音克隆攻击的有效防御

面对基于大型语言模型（LLM）的高拟真度语音合成攻击和基于自动语音识别（ASR）的端到端商业克隆攻击这两种新兴威胁，现有防御机制多针对传统语音合成模型，难以应对LLM驱动的“少样本”甚至“零样本”克隆攻击。此外，现有研究多依赖于“人工标注转录文本”这一强假设，忽略了实际攻击中广泛采用的自动语音识别（ASR）系统自动生成文本的端到端攻击范式。VoiceGuard对此展现了强大的防护能力，通过双路协同防御机制（音色保护+发音保护），能够同时破坏克隆语音的“身份相似性”和“内容准确性”，从根源上导致攻击失效。本作品在跨语言（中、英文）、跨平台（多个开源模型与商业API）进行了大规模测试验证了其广泛且有效的防护能力。

### 1.3.2 基于攻击链协同破坏的安全机制

VoiceGuard框架语音防克隆的安全性源于其针对语音合成攻击链的协同破坏机制，该机制通过双重路径实现了对合成语音质量和内容准确性的联合降解。在音色层面，VoiceGuard集成了音色编码器与梅尔频率倒谱系数（MFCC）特征提取器，通过融合多维度声学特征，实现了无目标与有目标两种保护机制，从而确保对说话人声纹信息的有效扰动。在发音层面，VoiceGuard基于对抗样本攻击自动语音识别（ASR）系统，通过误导其识别结果以输出错误文本，从而破坏预训练语音合成模型对文本-音频对齐关系的学习，干扰音频文本与语音合成之间的映射关系，使合成音频无法正确重构发音内容，实现对说话人发音的防克隆保护。

### 1.3.3 感知无损的音频扰动优化

为在保证强防御效力的同时维持音频的听觉自然性与应用可用性，本作品通过心理声学模型优化嵌入扰动的感知效果，并在损失函数中引入范数对扰动施加约束，以平衡扰动强度与不可感知性之间的权衡，增强其听觉自然性和不可察觉性。该方法利用人耳听觉系统的频域掩蔽特性，将对抗扰动精准注入到感知不敏感的频域能量区域，

并引入与人类听觉响应高度相关的L2范数对扰动幅度施加约束，从而实现扰动强度与不可感知性的科学平衡。VoiceGuard在信噪比（SNR）、语音质量感知评估（PESQ）等客观指标上表现优异，满足实际应用中对音频质量的高要求。

## 1.4 作品前景分析

本作品提出的主动式语音防克隆系统VoiceGuard，通过其前置性防御、高迁移性、感知不敏感性及对端到端微调场景的有效性等核心特性，结合不可学习样本、语音扰动隐藏、感知优化和数据毒化等核心机制，为应对生成式人工智能带来的音频安全挑战提供了一种有效、通用且鲁棒的语音克隆防护策略。在商业通信、金融服务、个人隐私保护以及社交媒体等领域具有广泛的应用前景。

### 1. 商业通信与企业安全防护

在商业通信与企业安全领域，该技术为解决企业高管欺诈（Business Email Compromise, BEC的语音形式）提供了强有力的技术保障。企业可将本框架部署于其对外通信链路中，对公开发布的新闻发布会、财报电话会议、内部动员讲话等关键音频内容进行保护性预处理。通过注入人耳不可感知的扰动，可以毒化任何试图以此音频为训练样本的语音克隆模型，能够有效防止商业竞争对手或恶意攻击者克隆企业领导者的声音，从而制造虚假商业指令、进行商业间谍活动或损害企业声誉，为企业的信息安全和商业信誉构建一道坚实的技术屏障。

### 2. 金融服务与生物认证安全

金融行业对身份认证的安全性有着至高要求，声纹识别因其便捷和不易遗忘的特性，正逐渐成为电话银行、移动支付和远程开户流程中的重要生物特征认证手段。然而，这也使其成为恶意攻击者的重点目标。金融机构可以使用VoiceGuard对存档的客户服务录音、声纹模板库以及语音操作指令进行保护性处理，即在客户注册声纹或日常交互语音被存入数据库之前，对其进行毒化处理。对于试图窃取数据库或截获通信以克隆用户声音的攻击者而言，这些数据将是无效甚至有害的，从根本上提升了生物特征数据库的安全等级，极大增强金融系统的反欺诈能力，更好地保障用户资金安全，有效防御针对声纹验证系统的绕过攻击和欺诈交易，符合金融行业严苛的监管合规与风控要求，满足《个人信息保护法》和《网络安全法》对生物特征信息保护的严格规定。

### 3. 个人隐私与数字身份主权维护

在个人隐私与身份安全保护方面，声纹是数字身份的核心构成要素之一，其泄露与滥用直接关系到公民的切身利益。随着个人语音数据在互联网上被广泛留存，其被滥用于实施冒充诈骗、情感勒索和名誉破坏的风险急剧上升。本作品提出的语音防克隆框架可被集成平台应用中，为用户提供个人语音数据的“主动免疫”功能。用户可对即将发布于社交媒体或发送至他人的语音文件进行预处理，确保其声纹生物特征不被恶意提取和滥用，从而避免遭受敲诈勒索、网络欺凌、社会工程学攻击和名誉侵害，有效捍卫个人隐私与数字身份安全。

### 4. 社交媒体与音频内容知识产权保护

对于社交媒体平台和内容创作者而言，音频内容的知识产权保护是一个日益尖锐的挑战。本作品提出的主动防御框架为音频IP保护提供了一种颠覆性的“主动防护”范式，即从传统的“发现侵权-事后追责”转变为“防止侵权-事前免疫”。在线教育机构可以保护其付费课程的有声内容，防止被轻易复制和用于训练模仿讲师的AI；音乐制作人可以为其实Demo小样添加保护，避免音色被未经授权挪用；虚拟偶像运营公司可以确保其投入巨资开发的标志性音色不被第三方轻易克隆和商业化滥用。而且，这种保护不依赖于可见数字水印，不会破坏内容的听觉体验，但其防护效果却更为根本，直接攻击了侵权行为的实现工具，即作用于AI模型训练阶段的“毒化水印”，能直接破坏未经授权的内容克隆和再生成行为，防止原创音色和音频内容被非法复制用于生成虚假言论或侵权产品，从而保障内容创作者的合法权益和经济收益。

随着人工智能和深度学习技术的不断发展，防克隆语音保护技术将会变得更加成熟和高效。通过不断优化和改进防克隆语音主动防御框架，增强其通用性、高效性、实时性和鲁棒性，可以进一步提升语音隐私保护的效果，使其在更多领域和场景中发挥作用，以应对不断变化的威胁环境。未来可以将防克隆语音保护技术与其他安全技术相结合，形成多层次的防护体系，提高语音通信的安全性和隐私保护水平。

## 第二章 相关技术介绍

在语音合成技术被滥用的背景下，本作品的核心目标是防止用户的语音数据被未经授权的语音合成模型成功克隆，从而保护说话人的声音隐私与身份安全。因此，在详细介绍本作品的系统设计与实现之前，有必要对涉及的关键技术进行简要说明。

语音合成技术是本作品防御机制的对抗基础与研究对象。它代表了攻击者所使用的技术手段，其发展水平直接决定了防御策略的挑战难度。2.1 节将首先介绍从传统参数合成到现代端到端神经网络的语音合成技术演进，重点剖析其模型架构与训练流程。理解攻击者如何利用该技术克隆目标音色，是我们设计有效防御方案的先决条件。

对抗攻击与防御技术为本作品提供了核心的扰动生成方法论。2.2 节将简要介绍该技术在语音领域的应用，包括几种不同的对抗攻击和对抗防御。最后，在 2.3 节将介绍数据毒化技术，从模型训练的数据源头为本作品提供了防御视角，是本作品中核心算法的重要组成。

### 2.1 语音合成

为了阐明作品的防御原理，首先介绍语音合成技术的概念和基本原理。语音合成（Speech Synthesis），又称文语转换（Text-to-Speech, TTS），起源于人机交互与信号处理领域，旨在通过算法生成可理解、自然流畅的人工语音。以现代深度学习为代表的生成模型（如 Tacotron、WaveNet 等）为例，在拥有大量高质量语音数据与对应文本语料的情况下，通过端到端的神经网络训练，可合成出高度接近人声的语音，甚至在自然度和表现力上达到以假乱真的水平。

研究表明，基于神经网络的生成方法能够有效建模语音中的韵律、音色和情感等细微特征，显著提升了合成语音的质量与适应性。在此基础上，又涌现出大量关注合成效率、多说话人建模、跨语言生成与个性化语音克隆的研究，推动了语音合成技术的广泛应用。我们意识到可将该技术用于无障碍服务、智能交互、媒体内容生成等领域，以提升信息获取与表达的便利性。当前所使用的语音合成系统多为基于神经网络的端到端生成模型。

### 2.1.1 深度神经网络

深度神经网络（Deep Neural Network, DNN）是机器学习领域中重要的模型架构，属于人工神经网络（Artificial Neural Network, ANN）<sup>[34]</sup>的扩展和深化。深度神经网络的关键在于利用多层非线性变换，从数据中逐层提取深层次的特征表示，使其具备对高维空间和复杂非线性问题的强大建模能力。典型的深度神经网络结构包括输入层、多个隐藏层以及输出层，每一层由多个神经元组成。这些神经元通过带有权重和偏置的连接进行信息传递，并借助激活函数引入非线性因素，从而增强模型的表达能力和拟合效果，其基本结构如图 2-1 所示。




图 2-1 深度神经网络

在深度学习的发展历程中，卷积神经网络（Convolutional Neural Network, CNN）是最早取得突破的一类模型。CNN 由 Yann LeCun 等人<sup>[35]</sup>提出并将之用于图像处理任务，通过卷积层提取局部特征，并利用池化层降低数据维度，从而有效捕捉图像的空间结构信息，例如经典的 LeNet-5 模型在手写数字数据集 MNIST 上的识别准确率能够达到 99%。2012 年，随着 AlexNet<sup>[1]</sup>在 ImageNet 竞赛<sup>[3]</sup>上取得革命性成果，深度神经网络被证明在图像任务上具备较大潜力并不断发展，更为先进的模型，例如 VGGNet<sup>[36]</sup>、ResNet<sup>[4]</sup>和 DenseNet<sup>[37]</sup>等，特别是 ResNet 通过引入“残差连接”解决了深层神经网络训练中的梯度消失问题，使得百层，甚至千层模型训练成为可能。

2017 年，Google 团队提出了 Transformer 架构<sup>[5]</sup>改变了现有深度神经网络的格局，其核心创新在于通过引入自注意力机制提升模型对于上下文信息的理解，Transformers 架构的基本结构如图 2-2 所示。与之前的模型不同，Transformer 摒弃了

传统的序列建模方式，通过计算输入序列中每个位置和其他位置的相关性捕捉全局的信息，这种方式能够有效增强对长距离依赖的建模能力。起初，Transformer 仅用于机器翻译任务，但是随着研究人员的不断深入探讨，Transformer 被广泛应用于各类自然语言处理任务，例如仅使用 Transformer 的编码器构成著名的 BERT 模型。BERT（Bidirectional Encoder Representations from Transformers）<sup>[38]</sup>通过双向编码器预训练和微调策略，在多项任务中取得了前所未有的性能。此外，GPT（Generative Pretrained Transformer）系列模型<sup>[39]</sup>使用 Transformer 的解码器，在多类生成式 AI 领域中展现了强大的能力，例如文本生成和对话系统等。




图 2-2 Transformer 架构

近年来，研究者基于 Transformer 架构和扩展法则，设计了众多能力更为出色的模型，例如 GPT-4<sup>[40]</sup>，DeepSeek<sup>[41]</sup>，Qwen2.5-Max<sup>[42]</sup>等。相较于小模型，大语言模型展现了出色的“上下文学习”（In-Context Learning）<sup>[43]</sup>和“少样本学习”（Few-shot Learning）的能力，展示了大语言模型在未见过的任务上的适应能力。

现代深度神经网络的蓬勃发展也推动着语音合成模型的进步。

### 2.1.2 传统语音合成

在深度神经网络普及之前，语音合成主要基于规则驱动、拼接式和统计方法和构建。基于规则的语音合成系统是语音合成的最早方式之一，常见的策略有共振峰合成<sup>[44]</sup>。这类方式通过人工设计的规则模拟语音生成的过程，通过控制基频、时长和共振峰频等声学参数，允许通过规则调整实现对韵律和语音细节的显示操作。

第二类是拼接式语音合成。在 1990 年代末至 2000 年代初，拼接式语音合成占据着主导地位，其通过拼接预录制的语音片段，例如单双音素，生成语音，而这些片段需要存储于大型数据库中<sup>[45]</sup>。该方法在拼接过程中可通过调整语音片段的基频、时长和幅度来修改韵律，还能通过选择不同说话人的语音单元实现有限的声音定制。

最后一类是统计参数化语音合成 (Statistical Parametric Speech Synthesis, SPSS)<sup>[46]</sup>。统计参数化语音合成是一种基于数据模型的方法，通过提取语音信号的关键特征，例如基频、频谱包络等，生成语音，经典的技术包括利用隐马尔可夫模型<sup>[47]</sup>建模语音的声学特征和语言学特征，从而实现从文本到语音的转换。相较于拼接式语音合成，该类方法能够有效降低对存储空间的需求，并实现了更平滑的语音单元过渡。

传统的语音合成技术虽然能实现一定程度的定制与控制，但更受限于底层模型和当时计算资源的约束，无法达到更优异的合成效果。

### 2.1.3 现代语音合成

深度神经网络的发展为语音合成技术提供了较强的架构，现代语音合成技术以深度神经网络为核心，充分利用大数据和强大的计算能力，实现了语音合成领域的跨越式发展。相比于传统方法，现代技术在语音质量、自然度和灵活性方面都有了质的飞跃，正在以惊人的速度发展，并不断拓展其应用场景。

#### 1. 基于扩散模型的语音合成

扩散模型 (Diffusion Model)<sup>[48]</sup>在图像生成领域取得了出色的表现，在语音合成中，DiffWave<sup>[49]</sup>模型利用扩散过程逐步生成语音信号，能够在一定程度上提升语音生成的自然度和细节表现。DiffWave 是一种基于扩散概率模型的语音合成算法，它通过逐步去噪的过程将随机高斯噪声转化为高质量的音频波形。该模型在训练阶段学习逆转预先定义的加噪过程，从而掌握从简单分布到复杂数据分布的变换规律；在推理阶

段则通过迭代去噪生成高保真的原始音频信号。DiffWave 因其出色的生成质量、对语音细节的精准捕捉以及稳定的训练特性，成为当时语音合成领域的重要突破，尤其在 高保真声码器和原始音频生成任务中表现出色。其基本架构如图 2-3 所示。




图 2-3 DiffWave 模型架构<sup>[41]</sup>

## 2. 零样本语音合成

零样本语音合成模型是一种仅需数秒目标说话人音频样本即可生成符合其音色特征的高质量语音的先进技术，其核心突破在于摆脱了对大量标注数据的依赖，通过解耦语音中的说话人身份信息与语言学内容实现跨说话人泛化。该类模型通常采用基于大型语言模型的生成架构或流匹配技术，将音频编码为离散符号并利用自回归预测或扩散过程学习语音表示的通用分布，最终实现仅凭未知说话人的短音频提示就能合成符合其音色、韵律和声学特征的自然语音，在语音克隆、个性化交互和多语言合成等领域展现出巨大潜力。

XTTS<sup>[51]</sup>基于 Tortoise 模型构建，并添加了若干新颖的修改，以实现多语言训练、改善声音克隆能力，并加快训练和推理的速度。XTTS 在 16 种语言中进行了训练，在其中大多数语言中达到了最先进的（SOTA）结果。其基本架构如图 2-4 所示。




图 2-4 XTTS 模型架构<sup>[43]</sup>

### 3. 基于大语言模型的语音合成

近年来，大语言模型（Large Language Models, LLMs）得益于其出色的上下文建模能力，更多的语音合成模型考虑嵌入 LLM 从而提升合成的质量。具体而言，采用音频编码器或标记器将输入波形编码为离散标记，并输入 LLM 进行学习，LLM 能够识别句子中更加细粒度的情绪、语气等，并将检测到的特征编码作为语音合成器的辅助输入，从而调节韵律、音高、能量等声学特征以贴合表达的情感等特征。将 LLM 融入语音合成技术标志着重要突破，推动语音合成向更具动态表现力和情感适应性的方向迈进<sup>[11]-[12]</sup>。




图 2-5 CosyVoice 模型架构<sup>[30]</sup>

CosyVoice 模型的架构结合了一个用于文本到标记生成的 LLM 和一个用于标记到语音合成的条件流匹配模型。这种两阶段方法将生成语义表示的任务与合成实际语音波形的任务分开，允许在每个阶段进行专门的建模。其基本架构如图 2-5 所示。

#### 4. 基于微调的端到端的语音合成

语音合成模型的微调依赖于多模态数据的输入，例如语音和其对应的文本模态。在传统的语音合成研究场景中，音频对应的文本能够从开源数据集中获取，所以文本信息不能改变，而只能改变语音信息。在现实世界中，个人主体如果希望训练一个高质量的语音合成模型，需要依赖于大量的音频和文本对，然而并不是所有的音频都直接具备文本信息，例如从Bilibili视频中提取的音频，在这种场景下的文本信息就需要依赖于自动语音识别获取文本，从而节省人工标注带来的时间和资源开销。自动化语音识别系统（Automatic Speech Recognition, ASR）是将给定音频转录成为文本的工具，文本对应于音频中的说话内容。目前，在微调语音合成模型时，文本信息通常由 ASR 系统进行转录得到，所以输入数据和输出数据均为音频，该场景被称为端到端微调（End-to-End Finetuning）。

VITS模型在端到端语音合成领域取得了突破性的进展。VITS将变分推断、归一化流以及对抗训练结合，通过隐变量建模与单调对齐机制实现从文本到语音波形的直接生成，避免了传统TTS系统对外部对齐工具和独立声码器的依赖。在训练阶段，模型学习文本与语音之间的隐式映射关系，并利用流模型进行灵活的分布建模；在推理阶段，可以高效地从隐空间采样并解码为自然流畅的语音信号。凭借端到端的结构设计、高保真的语音生成质量以及对韵律和音色的多样化建模能力，VITS广泛应用于高质量语音合成与实时语音生成等任务中。其基本架构如图2-6所示。




图2-6 VITS模型架构<sup>[9]</sup>

## 2.2 对抗攻击和防御

深度神经网络因其在多类任务上卓越的表现而被广泛使用，而这种能力的背后却潜藏着针对模型较大的脆弱性，当输入数据被施加人类难以察觉的细微扰动时，模型的预测结果可能发生灾难性偏移，这类恶意的诱导模型产生与真实值不同输出的行为被称为对抗攻击（Adversarial Attack），将细微扰动添加至原始音频后的样本成为对抗样本（Adversarial Examples）。对抗攻击深刻揭露了神经网络存在的脆弱性，并进一步引导了模型的鲁棒性发展。本节首先介绍对抗攻击，包括常见的白盒和黑盒攻击方式，随后介绍了对抗攻击的防御方法。

### 2.2.1 对抗攻击

2014 年，Szegedy 等人<sup>[52]</sup>发现对熊猫图像添加特定噪声后，模型竟以 99.3% 的置信度将其误判为长臂猿，而经过处理之后的图像和原始图像人眼看不出明显区别，如图 2-7 所示。这种精心制作用于模型判断的样本被称为“对抗样本”，这类异常现象不仅存在于计算机视觉领域，更渗透至自然语言处理、语音识别乃至强化学习系统，暴露出深度学习模型在高维特征空间中决策边界的高度敏感性。




图 2-7 在原始图像上添加细微扰动使得模型分类错误示意图

对抗攻击的目标在于通过对原始数据进行微调扰动使得模型的输出截然不同，公式化描述如公式（2-1）所示。

$$\underset{\delta}{\operatorname{argmax}} E_{(x,y)}[L(f(x + \delta), y)], \quad (2-1)$$

其中， $\operatorname{argmax}$  表示将目标函数最大化， $x$ 和 $y$ 分别表示输入的图像数据和其对应的标签， $\delta$ 为对抗攻击优化过程中产生的噪声并添加在原始数据中。 $f$ 为深度神经网络模型，

对输出图像经过模型判断的标签，而 $L$ 为损失函数，在分类任务中，通常为交叉熵损失函数。

公式（2-1）展示了通过优化扰动 $\delta$ 使得模型输出的标签和真实标签越来越大，导致模型对于输入数据判断错误，无法输出正确的标签，这类攻击方式被称为“无目标”对抗性攻击。进一步，如果攻击者希望通过优化扰动使得模型对于输入的数据输出指定的标签，这种方式使得输出标签朝着一个指定的目标优化的方式称为“有目标”对抗性攻击，需要将输出标签和目标标签 $y_t$ 之间的最小化，如公式（2-2）所示。

$$\operatorname{argmin}_{\delta} E_{(x,y)}[L(f(x + \delta), y_t)], \quad (2-2)$$

其中， $\operatorname{argmin}$  表示将目标函数最小化。

根据攻击者掌握的信息多少，对抗攻击主要可以分为白盒攻击和黑盒攻击。

### 1. 白盒攻击

白盒攻击是常见的对抗攻击方式，对于白盒攻击场景下，攻击者可以拿到模型的全部信息，例如梯度信息。相较于模型的输出标签，梯度能够反映网络内部每一层的变化情况以及损失函数对输入的敏感性。这意味着攻击者可以利用这些信息来有效地寻找输入空间中的对抗样本，通过计算梯度来优化输入以最大化模型的损失函数。常见的黑盒攻击方式可以分为基于梯度的快速梯度符号法、投影梯度下降算法和基于优化的 C&W 算法。

#### （1）快速梯度符号法（Fast Gradient Sign Method, FGSM）

白盒攻击中的一种经典方法，由 Goodfellow 等人<sup>[53]</sup>在 2014 年提出。FGSM 通过利用模型损失函数相对于输入数据的梯度信息来生成对抗样本。具体来说，这种方法计算损失函数对输入的梯度，并沿着梯度上升的方向对输入进行扰动，从而最大化损失函数。对于给定的输入样本 $x$ 和其真实标签 $y$ ，损失函数为 $L(f_{\theta}(x), y)$ ，其中 $\theta$ 是模型 $f$ 的参数。FGSM 攻击生成的对抗样本 $x'$  可以通过公式（2-3）计算得到。

$$x' = x + \epsilon \cdot \operatorname{sign}(\nabla_x L(f_{\theta}(x), y)), \quad (2-3)$$

其中， $\epsilon$ 为添加扰动的边界，通常被限制在一个很小的范围内，从而降低人类对添加扰动的感知。 $\operatorname{sign}(\cdot)$ 为符号函数，将输入的值映射为-1, 0, 1。 $\nabla_x L$ 表示对函数 $L$ 求变量 $x$ 的梯度操作。

#### （2）投影梯度下降（Projected Gradient Descent, PGD）

一种生成对抗样本的迭代攻击方法，是 FGSM 的一种扩展。与 FGSM 只进行单

步梯度更新不同，PGD 通过多步迭代优化的方式，在限制范围内生成更具欺骗性的对抗样本。PGD 被认为是目前最强大的攻击之一，尤其是在评估模型的鲁棒性和对抗训练的有效性时。

PGD 算法主要分为三个步骤：初始设置、迭代攻击、迭代停止。与 FGSM 算法的初始设置一致，给定的输入样本  $x$  和标签  $y$ ，损失函数为  $L(f_\theta, x, y)$ ，从随机初始化的对抗样本  $x_0$  开始，一般可以将其设置为原始输入  $x$  加上一个小的随机噪声。对于每次迭代  $t$  计算当前对抗样本  $x_t$  的梯度  $\nabla_x L(f_\theta, x, y)$ ，随后更新对抗样本得到  $x_{t+1}$ ，如公式 (1-4) 所表示。

$$x_{t+1} = \prod_{\epsilon} [x_t + \alpha \cdot \text{sign}(\nabla_x L(f_\theta, x, y))], \quad (2-4)$$

其中， $\alpha$  为单步的优化步长， $\Pi$  会将噪声大小限制在  $\epsilon$  大小的球内，保证更新后的样本不会偏离原始样本太远。

经过预设的迭代论述或达到某个停止条件，最终生成对抗样本。PGD 通过多次迭代，在原始样本所在的  $\epsilon$ -球限制范围内逐步调整，使得攻击效果更加显著。这种通过投影的方法确保在每一步都严格地保持对抗样本在规定的  $\epsilon$ -球内。由于其迭代特性，PGD 可以有效地逼近最坏情况下的攻击效果，是评估模型鲁棒性的重要工具。PGD 的强大之处在于其几乎可以抵达局部的最优解，使其生成的对抗样本非常具有侵略性，有助于揭示模型的弱点并用于发展更强的模型防御方法。

FGSM 和 PGD 算法为两种经典的基于梯度的对抗攻击方式，而 C&W 算法则为基于优化的对抗攻击算法。

### (3) C&W 算法

由 Carlini 和 Wagner 在 2017 年提出的一种生成对抗样本的攻击方法<sup>[55]</sup>，被认为是白盒攻击中的一种有效且强大的技术。与之前的基于梯度扰动方法不同，C&W 算法通过优化目标扰动直接攻击模型，使其分类错误，同时保持扰动的不可察觉性。

该方法的核心思想是构造一个优化问题，最小化扰动的大小，同时确保对抗样本被错误分类。C&W 对抗样本的计算方式如公式 (2-5) 所展示

$$\underset{\delta}{\operatorname{argmin}} \|\delta\|_p + cf(x + \delta), \quad (2-5)$$

其中， $\|\delta\|_p$  是扰动的  $L_p$ -范数， $c$  是一个平衡系数，用于控制扰动大小和分类错误之间的权衡， $f(x + \delta)$  是一个用于衡量对抗样本  $x_{adv} = x + \delta$  是否被错误分类为目标类别  $t$

的损失函数。

## 2. 黑盒攻击

黑盒攻击是指攻击者在无法获知模型内部细节（如网络结构、梯度信息等）的情况下，仅能通过观察模型的输出来实施攻击。这类攻击通常依赖于对模型行为的外部观察或推测。常见的黑盒攻击方法包括基于迁移性的攻击和基于梯度估计的攻击两种主要形式。

基于迁移的黑盒攻击方式是一种利用已知模型的对抗样本来攻击未知模型的方法。这种策略假设相似结构或同类的模型在面对相同的对抗样本时可能表现出相似的误分类倾向。因此，攻击者可以首先在一个白盒或半白盒环境中生成对抗样本，并期望这些样本能够成功地欺骗类似的黑盒模型。迁移攻击通常利用深度学习模型之间的通用特性和对抗样本的可迁移性，通过本地的替代模型产生迁移性较强的对抗样本实施攻击，这种方式无需对黑盒模型做查询，是一种有效而实用的黑盒攻击策略

相比之下，基于梯度估计的黑盒攻击方式，例如自然进化策略（Natural Evolution Strategies, NES）<sup>[56]</sup>通过查询目标黑盒模型来估计损失函数对于输入的梯度。即使攻击者对模型的内部结构和参数一无所知，NES 仍能通过随机采样和梯度近似方法有效地推进优化过程。通过不断地迭代查询和更新，NES 逐步逼近能够引发模型误分类的对抗样本。NES 体现了对黑盒场景的适应能力，通过进化策略实现高效的优化攻击，有力地揭示了模型在面对未知扰动时的脆弱性。

### 2.2.2 对抗防御

对抗样本揭露了深度神经网络在面对特定化攻击时的脆弱性，这种现象不仅挑战了深度学习模型的稳健性，也引发了对其安全性和可靠性的广泛关注。特别是在自动驾驶、医疗诊断以及金融决策等关键领域，错误预测可能导致灾难性后果。所以针对对抗样本的防御也是另一个热门的研究方向。常见的对抗防御方式包括数据增强和对抗性训练。数据增强通过扩充训练数据集来提高模型的泛化能力，而对抗性训练则直接将对抗样本纳入训练过程，使模型学会识别和抵抗恶意扰动。

#### 1. 数据增强

数据增强<sup>[58]</sup>技术是一种通过对原始训练数据进行有目的的变换与扩展以增加数据多样性和数量的有效方法，其核心思想是在不改变数据标签的前提下引入合理的变

异来模拟真实场景的复杂性。在图像领域常见操作涵盖旋转裁剪、色彩调整、混合样本等；而在语音领域，典型手段包括添加背景噪声、改变语速音高、进行时频掩蔽或应用房间脉冲响应模拟等。这种技术不仅能显著提升模型的泛化能力和鲁棒性，缓解过拟合问题，还能在有限标注数据的场景下有效扩大训练集规模，已成为深度学习模型训练中不可或缺的关键组成部分。

## 2. 对抗性训练

相比数据增强，对抗性训练是一种更为直接的防御策略<sup>[59]</sup>，其核心思想是将对抗样本的生成过程整合到模型训练中。具体而言，在每次训练迭代时，算法会针对当前模型参数生成对抗样本，并将这些样本与原始数据一起用于模型更新。这种在训练过程中添加对抗样本的方式迫使模型在学习任务本身的同时，也要学会抵抗精心设计的扰动。Madry 等人<sup>[60]</sup>提出的基于 PGD 的对抗性训练是目前最有效的防御方法之一，该方法通过多步迭代生成强对抗样本来训练模型，显著提升了模型在各种攻击下的鲁棒性。

防御技术的发展始终与攻击方法的演进保持着动态平衡的关系，这促使研究者不断探索更高效、更通用的防御方案，以应对日益复杂的对抗威胁。

## 2.3 数据毒化

深度神经网络模型的训练离不开大规模数据，如果攻击方或者数据发布方在数据中植入精心设计的恶意样本，就可能引发数据毒化（Data Poisoning）攻击<sup>[61]</sup>。这类攻击通过在训练数据中注入少量但具有特定模式的“毒化”样本，从而影响模型的训练过程，最终导致模型在测试阶段表现出预期的恶意行为。与对抗样本攻击主要针对模型推理阶段不同，数据毒化攻击瞄准的是模型的训练阶段，其影响更为深远且难以检测。常见的投毒攻击有基于标签翻转的数据投毒攻击<sup>[62]</sup>和干净标签的数据投毒攻击<sup>[63]</sup>等。

**1. 标签翻转的数据毒化**，通过将训练数据的标签进行翻转从而影响模型对于数据-标签对的学习，例如将图像标签“狗”翻转成“猫”的标签，从而使得模型在推理时识别出错误的标签。然而，这种简单的更改标签的方式很容易被对抗性策略防御，例如使用正则化或者数据处理等方式<sup>[62]</sup>。

**2. 干净标签攻击**是一种隐蔽性较高的数据投毒攻击<sup>[63]</sup>，核心特征在于攻击者只

能对数据的特征做修改，例如对原始数据添加扰动，而不改变图像原本的标签信息，所有毒化样本的标签在人类观察者看来仍然是正确的。传统的标签这种攻击方式很容易被数据清洗者发现，而干净标签攻击的中毒图像的标签与视觉是一致的，规避了传统基于标签异常的检测方法，对模型安全构成严重威胁。

干净标签攻击可以通过特征碰撞（Feature Collisions）实现。假设 $f(x)$ 计算图像 $x$ 的特征向量， $b$ 为原始数据集的图像， $t$ 为目标图像，那么特征碰撞的优化目标可以用公式（2-6）表示。

$$p = \underset{x}{\operatorname{argmin}} \|f(x) - f(t)\|_2 + \beta \|x - b\|_2, \quad (2-6)$$

其中， $p$ 为毒化后的图像。 $\|x - b\|_2$ 和参数 $\beta$ 用于限制毒化后图像和原始图像之间的差距，保证修改后的图像人眼无法明显察觉， $\|f(x) - f(t)\|_2$ 用于控制毒化后的图像和目标图像的特征之间的距离，使得图像 $p$ 在特征层面趋向于目标图像 $t$ 。

在训练过程中，攻击方使用特征碰撞将训练数据的特征与原标签不相同，从而实现不改变显示标签的条件下完成对模型训练的干扰，从而危害模型安全。

## 第三章 作品设计与实现

在构建了坚实的理论基础，并对语音合成、对抗攻击及数据毒化等核心关键技术进行深入剖析之后，本章将重点阐述本作品——“基于数据毒化的高鲁棒性防克隆语音保护系统”的具体设计与实现。

首先，我们将明确系统的设计目标，即构建一个能够有效抵御基于端到端微调的语音克隆攻击、同时保证扰动隐蔽性与系统实用性的保护框架。基于此目标，本节将详细阐述系统的总体架构与工作流程，从宏观层面展示数据处理、扰动注入与其他模块的协同机制。同时，我们将深入剖析系统的核心技术，重点介绍音色和发音的语音防克隆算法，以及基于心理声学模型的隐蔽性增强方法。最后，将具体描述系统各功能模块的实现细节，包括算法流程、关键参数配置与实时性优化，为后续的测试验证提供完整的实现依据。

### 3.1 系统设计目标

作品致力于在技术层面上提供尖端的语音通信隐私保护，确保用户的语音声纹隐私能够得到保护。我们特别关注于防御基于微调的端到端的语音合成系统，再发布前对在用户语音中加入扰动，显著提高攻击者的攻击成本，避免对用户语音的大规模克隆滥用，确保用户声纹隐私的的保密性。

因此，本作品设计开发一种名为VoiceGuard的语音防克隆保护系统，基于多种目标优化对抗扰动，包括对音色、发音的角度对扰动进行优化，保证有效的语音防克隆效果，同时使用心理声学模型和 $\mathcal{L}_2$ 损失来限制扰动的感知性，实现高鲁棒性、高音频保真度的针对基于微调的端到端微调的语音克隆系统的语音防克隆。

### 3.2 系统总体设计

作品在开发前做了充分的架构设计，将系统层次化、模块化，如图3-1，能够将复杂系统分解为清晰的层次和功能单元，从而有效降低复杂性，不仅提高了系统的可理解性和可维护性，还增强了可重用性与可扩展性，同时支持并行开发和故障隔离，保证了系统的可靠性与灵活性。

3.2.1 系统架构设计

1. I/O设备层

I/O设备层主要负责管理各进程之间的I/O传输，其中，物理I/O设备指的是用户通信设备上的音频输入物理设备（如：麦克风），负责用户通信音频的采样，作品将直接获取物理I/O设备的输入数据，传输给下一层。

2. 音频防护层

音频防护层负责为用户输入音频添加防护。其中，音频数据预处理模块负责对用户输入的音频数据进行预处理，调整采样位数，采样率和声道等参数，并添加到音频合成器的处理队列，音频合成器将下一层提供的对抗扰动添加到音频数据上。




图3-1 系统总体架构

### 3. 数据控制层

数据控制层负责获取并选择用于防护的对抗扰动。其中，扰动选择器将决定使用本地存储的对抗扰动还是云端存储的对抗扰动，本地缓存接口按照扰动选择器的指令从本地扰动库选取一个对抗扰动，也有将云端请求得到的对抗扰动缓存到本地的功能。云端请求接口按照扰动选择器指令向云端数据库请求对应的对抗扰动，也负责处理本地扰动库无缓存时的处理。

### 4. 数据存储层

数据存储层负责管理存储预先生成好的对抗扰动。本地无缓存时，将配合上一层接口请求从云端扰动库获取扰动并缓存到本地。云端扰动库则存储了云端生成层生成好的对抗扰动。

### 5. 云端生成层

云端生成层负责对抗扰动的生成，并将生成好的对抗扰动发送给上一层的扰动库。其中，音色保护模块在音色编码器集成的基础上，通过MFCC提取器结合声学特征，更好地扰动说话人身份特征。发音保护模块利用干扰ASR系统识别的对抗样本，使受保护的音频被识别为不同的文本，从而有效保护个人未经授权的音频数据。基于心理声学的感知优化模块与基于 $L_2$ 范数的扰动约束模块优化嵌入扰动的感知效果，以增强其自然性和不可察觉性。

### 3.2.2 系统工作流程

#### 1. 系统总体工作流程

如图3-2所示，系统的工作流程大致可以分为四个步骤：扰动生成，用户语音读取，音频防护添加，防护后阶段。




图3-2 系统总体工作流程图

### (1) 扰动生成

主要包括两个步骤：数据集处理和迭代优化。首先，要对训练数据进行预处理，如去除人耳无法识别的频率段等。然后，进入扰动生成以及迭代优化模块，具体的技术细节可以参考3.3节。在生成结束之后，生成的扰动作为可以将受保护的音频最大限度的在进行识别时偏离原音频的扰动，等待进行音频防护添加。

### (2) 用户语音读取

主要包括两个步骤：麦克风获取音频输入和音频数据预处理。麦克风获取音频输入对应系统架构I/O设备层的物理I/O设备，用于获取用户音频数据。在应用获取到麦克风的音频数据后，会对音频数据进行预处理，如调整采样位数，采样率和声道等。

### (3) 音频防护添加

对应系统架构音频防护层的音频合成器，负责将生成的扰动与预处理后的音频数据在数值上直接相加，生成新的波形图，即对抗样本。

### (4) 防护后阶段

此阶段是保护后的音频（防克隆音频），在防护后可以进行的操作。首先，我们可以获取防克隆音频的 $\mathcal{L}_2$ 、 $\mathcal{L}_{asr}$ 、 $\mathcal{L}_{fea}$ 和 $\mathcal{L}_{psy}$ ，这些参数可以帮助我们进一步优化防克隆音频以取得更好的防克隆效果。与此同时，也可以直接输出防克隆音频，当攻击者获取到这一受保护的音频时，它们无法使用防克隆音频进行基于大语言模型的端到端语音合成。

## 2. 系统业务逻辑流程

用户启动VoiceGuard应用，进入主页面，选择进入防御模式或查看历史记录。音频防护模块的业务逻辑流程如图3-3所示。

### (1) 初始化和文件检查

- ① 启动VoiceGuard防御模块并进行初始化。
- ② 检查本地是否有对抗扰动文件。若无或文件过期，从云端数据库获取并缓存到本地。
- ③ 加载并转换文件为张量以便处理。

### (2) 音频数据处理和缓存

- ① 打开用户音频输入设备并创建缓冲区保存音频数据流。

② 对音频数据进行预处理，调整采样位数，采样率和声道等参数并进行扰动添加。

③ 归一化音频数据并保存至数组，绘制原始音频波形图供用户查看。

④ 将音频数据进行缓存，并定时保存到本地。




图 3-3 VoiceGuard 业务逻辑流程图

### (3) 防护后数据处理和展示

① 处理后的音频数据转回数组格式，并绘制防护后的波形图展示给用户。

② 从防护后的音频数据中提取 $\mathcal{L}_2$ 、 $\mathcal{L}_{\text{asr}}$ 、 $\mathcal{L}_{\text{fea}}$ 和 $\mathcal{L}_{\text{psy}}$ ，供进一步优化使用。

③ 缓存处理后的音频数据，并定时保存至本地。

### (4) 音频数据输出

① 输出防护后的音频到虚拟设备，通话时读取防护后的音频，确保通话时的音频信息不被恶意利用。

② 提供用户选择是否生成自动语音识别（ASR）结果的选项。

### 3.2.3 系统功能模块




图3-4 系统功能模块图

本小节将介绍作品的功能模块，并列举每个模块的功能单元，简要描述不同模块之间的关系。整体功能模块如图3-4所示。

I/O控制模块是VoiceGuard的最外层，与客户端音频处理模块与进程通信模块交换数据，是音频数据进出系统的唯一通道。如图3-5，步骤1接收用户产生的原始音频输入数据流，步骤2完成原始输入音频数据预处理；接着，在客户端音频处理模块内部完成音频数据添加防克隆扰动后，步骤3将生成的对抗音频数据返回给I/O控制模块；最后，步骤4将VoiceGuard生成的防克隆语音数据流交付进程通信模块，后者执行步骤5将音频数据交付目标进程。




图3-5 I/O控制模块流程图

进程通信模块主要用于向目标进程（如腾讯会议、语音通话等）传输防克隆音频数据，实现进程间的通信，是系统外部与其他进程沟通的桥梁。

客户端音频处理模块是VoiceGuard的核心功能，将原始输入音频数据流添加扰动，得到保护后的音频，这一过程包含了针对添加扰动的感知优化。如图3-6，步骤1接收I/O控制模块发送的原始音频数据流；接下来两步，先进行输入数据流预处理，再通过VoiceGuard主动防御框架为输入的音频数据添加扰动，使语音防克隆保护生效；最后，步骤4将生成的防克隆音频数据流交付I/O控制模块。




图3-6 客户端音频处理模块流程图

音频历史数据模块是VoiceGuard的功能展示区，从客户端音频处理模块自动保存用户通信过程中产生的防克隆音频流并保存为音频文件，提供ASR转录服务与音频合成对比，供用户参考防御效果。如图3-7，步骤1实时获取用户的防克隆音频数据流，在用户发送完一次语音数据时将原始音频数据流和防克隆音频数据流分别保存为音频文件，通过步骤2存储到系统缓存中。在用户的操作下，可以通过步骤3读取VoiceGuard客户端启动以来保存的音频文件，通过步骤4自动转录成文本以及基于大语言模型合成的语音，进而在界面与音频波形图共同呈现原始音频与防克隆音频的波形图、两者被ASR转录的文本以及基于两段音频通过大语言模型合成的语音。




图3-7 音频历史数据模块流程图

### 3.3 系统核心技术

语音合成模型的微调依赖于多模态数据的输入，例如语音和其对应的文本模态。

在传统的语音合成研究场景中，音频对应的文本能够从开源数据集中获取，所以文本信息不能改变，而只能改变语音信息。在现实世界中，个人主体如果希望训练一个高质量的语音合成模型，需要依赖于大量的音频和文本对，然而并不是所有的音频都直接具备文本信息，例如从Bilibili视频中提取的音频，在这种场景下的文本信息就需要依赖于自动语音识别获取文本，从而节省人工标注带来的时间和资源开销。自动化语音识别系统（Automatic Speech Recognition，ASR）是将给定音频转录成为文本的工具，文本对应于音频中的说话内容。目前，在微调语音合成模型时，文本信息通常由ASR系统进行转录得到，所以输入数据和输出数据均为音频，该场景被称为端到端微调（End-to-End Finetuning）。本节聚焦于这种端到端微调的场景，提出了一种基于数据毒化的语音保护框架VoiceGuard，能够有效应对端到端语音合成带来的新的安全需求。

### 3.3.1 核心算法流程

研究人员发现使用对抗样本做数据毒化能够有效提升数据的不可学习性<sup>[66]</sup>，基于这一发现，本章提出了一种名为VoiceGuard的主动防御框架，从音色和发音两个角度使得合成的音频既低质量又与原音频说话人不相似。




图3-8 核心算法流程图

VoiceGuard实现语音保护主要基于针对ASR系统和特征编码器的攻击实现的，在针对特征编码器的语音保护中，需要确定是有目标还是非目标的保护策略。具体而言可以分为三个步骤。首先，需要先确定针对ASR系统攻击的目标文本和针对特征编码器的目标音频。对于有目标保护，目标的音频应该根据原始音频，从说话人数据库中选取特征差距最大的音频进行优化；对于非目标保护，目标音频应该为原始音频的负数，即使得原始音频朝着自身的反方向进行优化。随后，计算VoiceGuard设计的目标函数进行保护之后的音频，这一过程包含了针对添加扰动的感知优化算法。最后，根

据保护后的音频进行端到端的微调，验证基于数据毒化的主动防御框架VoiceGuard在语音防克隆保护的有效性，如图3-8所示。

### 3.3.2 端到端的语音保护

#### (1) 整体算法描述

从音色和发音的角度出发，本节实现了端到端的语音防克隆主动防御框架，VoiceGuard。在音色层面，以往的研究主要集中在有目标和无目标的保护上，即是否选择特定目标说话人进行音色扰动。VoiceGuard考虑了两种音色保护方法：有目标和无目标保护。在发音层面，利用针对ASR系统的对抗样本来实现发音保护。针对ASR系统的对抗性攻击主要为有目标攻击，即在优化过程中给定目标文本，确保ASR系统在经过特定处理的音频时会转录成特定的目标文本。这是因为在该场景下，转录出的文本希望是有意义的，而非乱码，从而降低对手对文本篡改的察觉。VoiceGuard整体的优化目标可以使用公式（3-1）进行描述。

$$\mathcal{L} = \mathcal{L}_{asr} + \alpha \cdot \mathcal{L}_{fea} + \beta \cdot \mathcal{L}_{psy} + \gamma \cdot \mathcal{L}_2, \quad (3-1)$$

其中， $\mathcal{L}_{asr}$ 表示ASR系统的损失， $\mathcal{L}_{fea}$ 为特征损失， $\mathcal{L}_{psy}$ 为基于心理声学模型的感知优化损失， $\mathcal{L}_2$ 为绝对值损失。 $\alpha$ 、 $\beta$ 和 $\gamma$ 为用于平衡多目标学习的权重系数。

#### (2) 音色保护

语音合成模型通常利用输入的参考语音样本来生成高质量且音色相似的音频。VoiceGuard通过实现音色层面的语音保护，达成防克隆的语音保护目标，并确保克隆音频与原始说话人的音色存在差异。以往的研究主要依赖编码器进行音色提取和优化，从而在原始音频和目标音频之间制造音色差异。在音色编码器集成的基础上，本章进一步通过梅尔频率倒谱系数（Mel Frequency Cepstral Coefficient, MFCC）提取器结合声学特征（包括音色、发音和风格），以更好地扰动说话人身份特征。在设计VoiceGuard时，本章提出了两种保护方法：有针对性和无针对性的音色保护。

- **无目标音色保护。**无目标保护最大化原始音频 $x$ 和受保护音频 $x'$ 之间的特征距离，使合成的音频无法被识别为原始说话人。零样本语音合成模型通常使用编码器提取与克隆相关的特征，例如CosyVoice中的音色编码器和StyleTTS2中的风格编码器，并将这些特征与预训练的发音模式结合以进行语音合成。基于先前研究表明通过编码

器集成可提高可迁移性，VoiceGuard从目标语音合成模型中通过多个编码器提取音色和声学特征，以增强对未知模型的保护通用性。此外，VoiceGuard还整合了MFCC特征，以保护发音和韵律模式。非目标音色保护的目标函数如公式（3-2）所示。

$$\mathcal{L}_{fea} = \sum_{i=1}^k \text{Cos\_Sim}(E_i(x), E_i(x')) + \text{Cos\_Sim}(M(x), M(x')), \quad (3-2)$$

其中， $x'$ 表示被保护的音频，通常由原始音频 $x$ 加上噪声 $\delta$ 构成，即 $x+\delta$ 。 $k$ 是用于优化的编码器的数量， $\text{CosSim}(\cdot)$ 用于计算余弦相似值，范围从-1 到 1。 $E(\cdot)$ 为选择的编码器，用于计算输入音频的音色信息。 $M(\cdot)$ 表示MFCC特征提取器。

• **有目标音色保护。**有目标保护将原始音频特征引导至指定的目标说话人 $x_t$ ，使得语音合成模型生成趋近于目标说话人的音频。在目标选择方面，本章参考AntiFake<sup>[25]</sup>构建了一个说话人数据库，并通过特征距离为每个受保护的音频选择与原始音频 $x$ 最不相似的说话人。相比随机选择异性样本的策略，例如AttackVC和VSMask所采用的，这种方法能够系统地选择在各项特征上与原始音频差异最大的 $x_t$ 。有目标音色保护可以使用公式（3-3）表示。

$$\mathcal{L}_{fea} = - \sum_{i=1}^k \text{Cos\_Sim}(E_i(x_t), E_i(x')) - \text{Cos\_Sim}(M(x_t), M(x')), \quad (3-3)$$

上述两种方法都能有效保护说话人身份。无目标音色保护由于没有明确的优化目标，能够实现更广泛的对抗样本探索；而有目标音色保护则利用精心挑选的特征差异样本，进一步增强音色的扰动效果。

### (3) 发音保护

微调语音合成模型需要文本和音频数据对，以实现发音和文本之间的对齐。例如VITS模型使用单调对齐搜索（Monotonic Alignment Search, MAS）算法<sup>[68]</sup>来查找时间帧与字符之间的对应关系。文本数据可以通过人工标注或ASR系统自动识别获得。前者耗费大量人力、时间和成本，因此更常见的是使用ASR系统来识别文本信息。以往的研究表明，ASR系统相对脆弱，容易受到对抗样本的干扰，从而影响识别准确性。基于这一发现，本章考虑利用对抗样本来干扰ASR系统的识别，使受保护的音频被识别为不同的文本。错误的文本-音频数据会对破坏预训练语音合成模型对发音信息的学习，防止根据期望的文本合成具有相应发音的音频，从而有效保护个人未经授权的音频数据。

针对ASR系统的对抗攻击也可以分为有目标和无目标两种类型，区别在于优化过程中是否提供特定的目标文本。无目标攻击生成的文本是不连贯的，而有目标攻击通过指定目标文本来确保识别文本的可读性，从而有效降低对手对异常识别文本的察觉。因此，本章选择对ASR系统进行有目标攻击。目标文本的选择会影响对抗样本的有效性。例如，较长的音频与较短的目标文本配对时，可能导致识别文本的后半部分保留原始正确文本，这需要进一步优化考虑。因此，本章需要考虑所选文本及其长度。上述部分关于音色的有针对性攻击中，由于所选音频已包含与原始音频不同的特定发音信息，并且根据之前的研究，MFCC的应用也有助于ASR系统在对抗样本优化中对目标音频文本的识别，本章设计时选择目标音频的文本作为目标文本。对于音色的无针对性攻击，为不同音频选择与其长度相同的文本，更有助于针对ASR系统的对抗攻击。综上，发音层面的保护如公式（3-4）所表示。

$$\mathcal{L}_{asr} = \mathcal{F}(ASR(x'), y_t), \quad (3-4)$$

其中， $\mathcal{F}$ 为ASR系统的目标函数，例如Wav2vec2模型使用的CTC（Connectionist Temporal Classification）损失。 $ASR(\cdot)$ 根据输入的音频计算ASR模型的输出信息，例如识别文本的概率分布。 $y_t$ 为目标文本。通过优化公式（3-4），敌手使用ASR系统后获取到错误的文本信息，从而干扰预训练模型对于文本-音频的对齐过程，导致合成的音频无法正确发音。

#### (4) 基于心理声学模型的感知优化

心理声学（Psychoacoustic）<sup>[69]</sup>研究发现嵌入到特定区域的扰动会被掩盖，使得人耳无法听到该区域的声音，这种现象被称为掩蔽效应<sup>[70]</sup>，如图3-9所示。




图3-9 掩蔽效应示意图

利用这一特性，本节通过心理声学模型优化嵌入扰动的感知效果，以增强其自然性和不可察觉性。掩蔽效应可以分为时间掩蔽和频率掩蔽。按照V-Cloak的设置，本章采用频率掩蔽部分，以确保扰动对人耳来说是不可察觉的。

将原始音频设为掩蔽源，使扰动（被掩蔽部分）保持在掩蔽阈值以下。设 $S$ 表示频率总数， $\theta_x$ 表示原始音频 $x$ 的掩蔽阈值，其中每个元素表示在频率 $f$ 处可接受的最大扰动。假设 $p_x$ 表示音频 $x$ 的对数幅度功率谱密度（Power Spectral Density, PSD）。因此，心理声学模型的目标函数可以表示为公式（3-5）。

$$\mathcal{L}_{psy} = \frac{1}{F} \sum_{f=1}^F \max(0, p_{x'-x}(f) - \theta_x(f)), \quad (3-5)$$

其中， $\max(0, \cdot)$ 确保得到的值为非负数。

此外，本章通过 $\mathcal{L}_2$ 范数对扰动施加约束，因为Duan等人<sup>[71]</sup>发现，在 $\mathcal{L}_p$ 范数中， $\mathcal{L}_2$ 与人类感知的相关性表现最佳。因此，本章通过引入 $\mathcal{L}_2$ 进一步降低嵌入扰动的可感知性，如公式（3-6）所示

$$\mathcal{L}_2 = \|x' - x\|_2, \quad (3-6)$$

## (5) 算法总结

之前部分系统地介绍了目标函数 $L$ 的组成部分及其具体实现。通过最小化目标函数 $L$ 来生成对抗扰动，这一过程可以形式化地表示为公式（3-7）。

$$\operatorname{argmin}_{\delta} (x, x', x_t, y, y_t), \quad (3-7)$$

其中，约束条件为 $\|\delta\|_p \leq \epsilon$ 并且音频的值应该在-1到1之间。

VoiceGuard采用投影梯度下降（Projected Gradient Descent, PGD）算法，通过迭代优化和更新扰动样本 $x'$ ，同时在每一步中最小化 $\mathcal{L}$ ，如公式（3-8）所示。

$$x' = \prod_{\epsilon} (x - lr \cdot \operatorname{sign}(\nabla_x \mathcal{L})), \quad (3-8)$$

其中， $\prod_{\epsilon}$ 表示投影到 $\epsilon$ -球约束的投影算子， $lr$ 表示学习率（或步长）， $\operatorname{sign}(\cdot)$ 是符号函数， $\operatorname{sign}(\nabla_x \mathcal{L})$ 表示损失函数 $\mathcal{L}$ 对变量 $x$ 的梯度。

## 3.4 系统功能实现

### 3.4.1 音色保护模块

音色保护模块集成了音色编码器与梅尔频率倒谱系数（MFCC）特征提取器，通过融合包括音色、发音与风格在内的多维度声学特征，实现对说话人身份信息的有效扰动。该模块实现了无目标与有目标两种保护机制：无目标音色保护通过多编码器结构提取广义声学特征，并引入MFCC以增强对发音与韵律模式的覆盖，从而在不设定明确优化目标的条件下提升对抗样本的探索能力与模型泛化性；有目标音色保护则基于构建的说话人数据库，通过特征距离为每段语音选取最不相似的说话人样本，以实现定向强扰动。两种机制均能有效保障说话人身份安全，无目标方法侧重于通用性与广泛扰动，有目标方法则侧重于依据特征差异实现精准高效的身份混淆。核心代码实现如下：

```
01 def compute_feature_loss(self, embs_1, embs_2):
02     loss = 0.0
03
04     encoder_weight_cosyvoice = 0.5
05     for index, (emb_1, emb_2) in enumerate(zip(embs_1, embs_2)):
06         try:
07             score = self.criterion(emb_1, emb_2).mean()
08         except:
09             # For VITS, GSV, MFCC, WavLM
10             min_len = min(emb_1.shape[2], emb_2.shape[2])
11             emb_1 = emb_1[:, :, :min_len]
12             emb_2 = emb_2[:, :, :min_len]
13             score = self.criterion(emb_1, emb_2).mean()
14
15         if (index + 1) == 5: # CosyVoice Encoder
16             score = score * encoder_weight_cosyvoice
17
18         loss = loss + score
19
20
21     return loss
```

### 3.4.2 发音保护模块

发音保护模块基于对抗样本攻击自动语音识别（ASR）系统，通过误导其识别结果以输出错误文本，从而破坏预训练语音合成模型对文本-音频对齐关系的学习，有效防止未经授权合成具有目标发音的个人音频。

本模块采用以目标音频文本为攻击目标的有目标攻击策略，并为不同音频选取长度匹配的干扰文本，以增强对抗样本的有效性。通过构造错误的文本-音频对应关系，干扰音频文本与语音合成之间的映射关系，使合成音频无法正确重构发音内容，实现对说话人发音特征的有效保护。核心代码实现如下：

```
01 def compute_asr_loss(self, adv_wave_16k
02     , target_text, ori_text=None):
03     target_text = target_text.upper()
04
05     with open('tts_models/configs/vocab.json'
06         , encoding='utf-8') as a:
07         vocab = json.load(a)
08
09     labels = torch.tensor(self.text2id(target_text, vocab))
10
11     output = self.asr_model(adv_wave_16k, labels=labels)
12     loss_asr = output.loss
13
14     return loss_asr
```

### 3.4.3 感知优化模块

基于心理声学中的掩蔽效应，本模块利用心理声学模型对嵌入扰动进行感知优化，以提升其不可察觉性与听觉自然性。

具体而言，本模块依据人耳听觉特性，将扰动嵌入至频域中可被掩蔽的敏感区域，并借助频率掩蔽技术，使得扰动被原有音频信号所掩盖，从而确保人耳难以察觉，在增强对抗干扰效果的同时维持了音频的主观感知质量。核心代码实现如下：

```

01 msker = Masker(device=self.device, sample_rate=sr)
02 theta, original_max_psd = msker._compute_masking_threshold(
03     wave[0].cpu().numpy())
04 theta = torch.FloatTensor(theta.transpose(1, 0))
05 original_max_psd = torch.FloatTensor([original_max_psd])
06 theta_batch = theta.unsqueeze(0)
07 original_max_psd_batch = original_max_psd.unsqueeze(0)
08
09 loss_psy = msker.batch_forward_2nd_stage(
10     local_delta_rescale=(adv_wave - wave).squeeze(1),
11     theta_batch=theta_batch.to(self.device),
12     original_max_psd_batch=original_max_psd_batch.to(self.device),
13 )
14
15 loss_psy_max = 1.0e7
16 if torch.isnan(loss_psy) or torch.isinf(loss_psy):
17     loss_psy = torch.FloatTensor([loss_psy_max]).to(self.device)
18 elif loss_psy > loss_psy_max:
19     loss_psy = torch.FloatTensor([loss_psy_max]).to(self.device)

```

#### 3.4.4 扰动约束模块

本模块采用 $L_2$ 范数对生成的扰动施加约束。在 $L_p$ 范数体系中， $L_2$ 范数因其与人类听觉感知特性具有更高的相关性，能够有效平衡扰动强度与不可感知性之间的权衡。通过引入 $L_2$ 范数约束，本模块进一步抑制了扰动的可察觉程度，从而在维持对抗效果的同时，增强音频质量的主观感知自然性。核心代码实现如下：

```

1 | loss_l2 = torch.norm(adv_wave - wave, p=2)

```

### 3.5 系统应用实现

本节介绍本系统具体应用前端的实现，其主要界面如图3-10所示。在该界面中，用户可以选择启动VoiceGuard防御模块、查看防御效果或进入历史数据模块查看历史通信记录。以下将分别介绍这几个模块。



图3-10 VoiceGuard主界面

### 3.5.1 音频保护模块

当用户进入VoiceGuard主界面时，系统将会将音频防护模块初始化，为用户输入的音频执行系统核心的防御流程。如图3-11所示



图3-11 VoiceGuard音频保护模块

**1. 系统初始化：**用户访问VoiceGuard主页面后，本系统会先进行初始化操作，完成对抗扰动生成过程中需要用到的ASR模型、音色保护中的特征Encoder等模块的部署。

**2. 获取用户输入：**通过实时录音，上传录音文件的方式获取原始音频，将音频上传至服务器生成音频的ASR结果和波形图，直观地向用户展示音频效果。系统会创建缓冲区，用以保存用户音频输入设备产生的音频数据，后续的各种音频数据同理。

**3. 音频数据预处理：**用户上传音频后，系统会调整音频的采样率以适应后续保护和克隆模块的要求。进行实时录音时，系统会自动设置采样位数、采样率和声道数等音频质量参数。

**4. 音频防护与保存：**用户上传音频或录音完成后，会自动将音频文件上传到后端服务器，随后后端会为音频生成波形图和ASR转录文本，便于与后续的保护音频做对比

**5. 对抗音频和效果输出：**点击“保护”按钮，后端程序会根据输入音频，根据设计好的目标和损失函数生成对抗扰动，将对抗扰动添加到原始音频中，生成无法被端到端语音合成系统利用的保护后音频。后端系统也会为保护音频生成波形图，便于用户直观地感受保护前后的音频质量效果，同时使用ASR系统对音频进行转录，直观

表现保护音频中ASR目标的效果。

### 3.5.2 保护效果展示模块

为了表现本系统进行语音防克隆保护的完整效果，系统中还设计了模拟攻击者使用的基于微调的端到端的语音合成系统，用户可以将原始音频和保护后音频分别尝试进行语音合成，展示保护的效果，如图3-12所示。



图3-12 VoiceGuard保护效果展示模块

使用系统中的保护效果展示模块的步骤如下：

- 1. 选择目标TTS方法和目标文本。**用户可以从StyleTTS2、GSV和VITS三种常见的语音合成方法中任选其一，并输入一段文本指导目标音频的合成。
- 2. 目标语音合成。**点击“执行语音克隆”后，系统将保护前后的两段音频上传到后端，根据用户选择的语音合成模型和目标文本分别进行语音合成，并回传至前端。
- 3. 合成音频和效果输出。**后端除了会按需求执行语音合成过程生成合成语音，还会和保护模块中一样生成音频对应的波形图和ASR转录文本，用于直观地表现保护前后的克隆效果。

### 3.5.3 历史记录查看模块

历史数据模块，其功能是让用户能够查看历史通讯记录，包括原始音频波形与转录文本以及防护后音频波形与识别结果，从而更好地理解 and 评估防御模块的效果。VoiceGuard的历史记录查看模块如图3-13所示。



图3-13 VoiceGuard历史记录查看模块

用户可以在页面底部历史记录模块查看历史保护和合成列表。历史记录按照按时间检索，用户只需要点击对应的记录展示框就可以将对应的四个音频（原始音频、保护音频、原始克隆音频、保护克隆音频）加载到上方的音频展示框，并且可以重新运行保护和克隆步骤，仔细地检查保存的音频文件，充分理解和认识语音防克隆的基本原理和效果。

整个历史保护记录查看模块流程设计充分考虑了用户的需求和使用习惯，通过直观的界面和交互设计，使用户能够方便地查看和验证历史通讯记录，了解防御模块的效果和性能。在还没有任何历史记录时，历史通讯查看模块效果如图3-14所示。



图3-14 无历史记录的历史记录模块

## 第四章 作品测试与分析

在本章中，我们选择了具有不同结构的多种语音合成模型作为目标模型分别进行了技术性能测试与实际应用测试，以验证作品所采用的语音保护方法的有效性，以及作品在实际应用场景中的可靠性。将从三个方面进行展开：首先介绍整体的实验设置，包括数据集、评价指标、测试环境、使用的语音合成模型和 ASR 系统等。其次简要介绍我们的测试方案，一是针对不同 ASR 系统的保护效果的测试方案，旨在展示我们方法在不同 ASR 系统上的保护有效性与不可察觉性，二是针对多说话人或多语言场景下的测试方案，验证我们的方法有效防止了多说话人端到端微调场景下的发音和音色泄露，三是验证 VoiceGuard 的有效性的迁移性实验，四是进行了感知分析，五是消融实验，六是对 VoiceGuard 在现实世界中的有效性和鲁棒性进行评估。最后针对上述测试方案的测试结果分别进行详细分析。进行系统功能测试，展示系统的基本使用方法和实际应用效果。

### 4.1 测试设置

#### 4.1.1 数据集

LibriTTS 是一个专为文本到语音合成研究设计的大规模、多语言英语语料库。它源自著名的 LibriSpeech 数据集，而 LibriSpeech 本身是从 LibriVox 项目的有声读物中提取的。LibriTTS 对原始音频进行了重新处理和组织，以更好地满足现代 TTS 模型训练的需求，特别是端到端的神经 TTS 系统。然而，攻击者可能会使用多说话人或多语言场景下的语音样本。为了解决这一问题，我们在 CMU ARCTIC（多说话人数数据集）和 THCHS30（多说话人普通话数据集，针对 Wav2vec2 模型）上验证了我们的方法。每个数据集均按 80%训练集与 20%测试集随机划分，若模型需验证集则从训练集中抽取 10%作为验证集。

## 4.1.2 测试环境

### 1. 硬件环境

|    |         |                                                                               |
|----|---------|-------------------------------------------------------------------------------|
| 训练 | 机型      | SYS-G4000 / 塔式静音工作站                                                           |
|    | 电源      | 2000W 服务器电源                                                                   |
|    | Network | 双口千兆网口+IPMI 专用管理网口                                                            |
|    | GPU     | NVIDIA GeForce RTX 4090                                                       |
|    | CPU     | 4th Gen Intel® Xeon® Scalable processors<br>2x Intel® Xeon® 2.4Ghz 48 核 96 线程 |
|    | 内存      | 三星 8X 64G DDR5 4800 REG                                                       |
|    | SSD     | 三星 960G M.2 NVME SSD OS                                                       |
|    | HDD     | 西数 16T SATA 3.5 寸 企业级 HDD                                                     |
| 测试 | CPU     | 4 核, Core i5-2500K                                                            |
|    | 主频      | 2.80GHz                                                                       |
|    | 内存      | 16GB                                                                          |

### 2. 软件环境

|    |         |                          |
|----|---------|--------------------------|
| 训练 | CUDA 版本 | 12.2                     |
|    | 深度学习框架  | Pytorch 2.1              |
| 测试 | 操作系统    | Windows 11               |
|    | 驱动程序    | 麦克风阵列 Realtek 6.0.9597.1 |

## 4.1.3 目标场景

本章选择了具有不同结构的多种语音合成模型，以进行更全面的评估，主要分为微调模型和零样本克隆模型。零样本克隆模型不仅可以实现零样本语音克隆，还可以用于微调，而微调模型不具备零样本能力。对于微调模型，我们选择了具有出色微调能力的经典模型，包括 VITS 和 MBV。关于零样本克隆模型，本节选择了采用最新语音克隆技术的模型，这些模型仅需约 5 秒的参考音频即可合成人类水平的语音，包括 StyleTTS2、GPT-SoVITS（GSV）、F5-TTS 和 CosyVoice。

在真实场景中，对手可能会采用不同的 ASR 系统从音频中识别文本信息。我们针对 ASR 系统开展模型特异性对抗攻击，并能有效诱导误分类。实验选取了七种 ASR 模型，包括 Wav2vec2<sup>[73]</sup>、Whisper（base, small, medium, and large）<sup>[74]</sup>、Conformer<sup>[74]</sup>，以及 CitriNet<sup>[75]</sup>。我们使用表 4-1 展示这些 ASR 系统的详细比较。这些差异主要涵盖了声学模型、损失函数类型以及通过 WER 衡量的识别性能。

表 4-1 所选 ASR 系统的详细信息和比较

| 模型        | 声学模型              | 损失函数类型        | WER 衡量的识别性能 (%)                                    |
|-----------|-------------------|---------------|----------------------------------------------------|
| Wav2vec2  | Transformer & CNN | CTC           | 3.4                                                |
| Whisper   | Transformer       | Cross Entropy | 5.0 (base) 3.4 (small)<br>2.9 (medium) 2.7 (large) |
| Conformer | Transformer       | CTC           | 3.7                                                |
| CitriNet  | CNN               | CTC           | 4.4                                                |

从表 4-1 可以看出，我们所选模型大多采用两类主干架构，即 Transformer 和 CNN，并使用多种不同的损失函数。我们特别包括了 Whisper 模型，这是一个多语言 ASR 系统，以其高识别精度而闻名。其中最大版本 large-v3 在 LibriSpeech test-clean 数据集上的 WER 仅为 2.7%，表现最佳。选取的七个 ASR 系统涵盖了四大类主流技术，有效代表了自动语音识别的现状。

在模型微调过程中，本节遵循模型提供方所设定的常规配置，同时对关键超参数进行了适当调整，以在防护有效性与扰动不可感知性之间取得平衡。具体而言，参数  $\alpha$ 、 $\beta$  与  $\gamma$  分别设置为 500、5e-3 和 0.1，扰动边界  $\epsilon$  取值 8/255，并在此约束条件下对扰动进行 500 次迭代优化。

之前的语音保护工作主要聚焦于使用对抗样本对原始音频的音色进行保护，从而使得合成的音频与说话人并不相似，例如 AttackVC 和 AntiFake 技术。本章将 AttackVC 和 AntiFake 技术作为本作品的方法对比基准（Baseline）。

基于对抗样本的语音保护具体而言，给定来自说话人受害人  $i$  的一个干净样本  $\mathbf{x}$ ，通过编码器计算该说话人的音色特征  $\mathbf{E}_i$ 。随后，在 AntiFake 方法中，选择与  $\mathbf{E}_i$  音色最不相似的目标说话人  $j$  的。在 AttackVC 方法中随机选择性别相反的说话人，并提取其音色特征  $\mathbf{E}_j$ 。通过对原始样本  $\mathbf{x}$  添加扰动，使得  $\mathbf{E}_i$  逐渐接近  $\mathbf{E}_j$ ，从而完成语音保护，

导致生成的语音与原始说话*i*的音色产生差异。

#### 4.1.4 评价指标

为了更加全面地评估本作品语音保护框架的保护效果，本章考虑了客观和主观评价指标，分别验证有效性和不可感知性。

##### 1. WER (Word Error Rate, 单词错误率) (%)

WER 通过预训练的 OpenAI 公司开源的语音识别模型 Whisper (medium 尺寸模型) 识别音频对应的文本，用于评估发音清晰度。MCD 和 WER 值越高，表明语音清晰度越差，以此实现对合成质量的保护，其计算方法如公式 (4-1) 所示。

$$WER = \frac{S + D + I}{N} \times 100\%, \quad (4-1)$$

其中，S 表示替换 (Substitutions) 的数量，即识别结果中被错误替换的词语个数；D 表示删除 (Deletions) 的数量，指的是参考文本中存在但识别结果中遗漏的词数；I 表示插入 (Insertions) 的数量，代表识别结果中多出的、在参考文本中未出现的词语数量；N 则为参考文本中的总词数。

##### 2. SIM (Speaker Similarity, 说话人相似度)

SIM 是衡量两段语音音色相似度的指标，数值越高表示音色相似性越大。本作品采用 ECAPA-TDNN 模型<sup>[72]</sup>作为说话人编码器，计算真实语音与合成语音的余弦相似度得分。SIM 指标的计算方式如公式 (4-2) 所示。

$$SIM = \text{CosSim}(E(x), E(\hat{x})), \quad (4-2)$$

其中，CosSim(·) 表示余弦相似度，范围在 -1 到 1 之间，越高意味着输入的两个数据相似性越高。*x* 和 *ŷ* 分别表示真实音频和合成音频。E 为音色编码器，根据给定的音频计算说话人的音色特征。

##### 3. SNR (Signal-to-Noise Ratio, 信噪比)

SNR 通过计算嵌入扰动信号与原始音频的比率，衡量扰动音量水平。单位为分贝 (dB)，数值越高表明语音质量受干扰越小。SNR 指标的计算方法如公式 (4-3) 所示。

$$SNR = 10 \cdot \log_{10} \frac{P_s}{P_N}, \quad (4-3)$$

## 4. PESQ (Perceptual Evaluation of Speech Quality, 语音质量感知评估)

PESQ 是一种客观语音质量评估指标，由国际电信联盟电信标准化部门 (ITU-T) 在 P.862 标准中提出，用于替代早起的 PSQM、改进对语音通信质量的客观测量。PESQ 模拟人耳的听觉感知过程，将原始语音信号与经过处理或传输的语音信号进行对比，从而给出一个分数来衡量语音质量，范围为-0.5 到 4.5。

在本测试中，数据保护效果评估采用 WER 和 SIM 指标，添加扰动的感知使用 SNR 指标。

## 4.2 测试方案

### 4.2.1 技术性能测试

在性能测试中，我们选取了多种 ASR 系统、语音合成模型和贴近现实的场景等，并采用了如下的测试方案，针对本作品多种方面的实际性能进行了测试：

**1. 针对不同 ASR 系统的防护性能：**为验证本作品在跨模型环境中的适用性，我们在多种主流 ASR 系统上进行实验，包含了两种主要的架构，即 Transformer 和 CNN，并且采用了不同的损失函数类型，因此这些 ASR 系统有效的代表了当前自动语音识别领域的主流技术。

**2. 多说话人和多语言场景下的防护性能：**考虑到显示应用中常常涉及多个说话人的语音，以及不同语言的输入，我们分别在 CMU ARCTIC（多说话人数据集）和 THCHS30（多说话人普通话数据集）上对本作品的防护性能进行测试，基本覆盖了现实使用场景。

**3. 有效性和迁移性：**针对语音防克隆的场景，我们使用 VoiceGuard 以无目标和有目标模式保护 LibriTTS 数据集，并设置统一的 ASR 系统使用 6 种主流的语音合成模型在微调后生成语音，验证本作品的防护有效性和迁移性。

**4. 感知分析：**除了模型性能指标外，我们还从人类感知的角度进行评估，通过噪声比这一重要性能指标考察本作品在音质保持、可懂度和自然性方面的影响，确保其在真实交互场景中不会降低用户体验。

**5. 消融实验：**为了深入理解本作品的关键组成部分及其作用，我们设计了消融实验，逐步移除或替换不同模块，分析各部分对整体性能的贡献，从而验证设计的合

理性与必要性。

**6. 鲁棒性：**针对可能存在的环境噪声、录制条件变化和信道干扰等因素，我们在多种噪声水平和设备条件下进行实验，验证本方法在复杂实际环境中的稳定性与鲁棒性。

#### 4.2.2 实际应用测试

实际应用测试关注的是作品在实际应用和现实场景中的有效性，具体而言，在实际应用中，我们主要关注以下几个环节：

1. 用户上传或录制音频数据；
2. 音频数据预处理和保护；
3. 原始音频和被保护音频合成效果测试；
4. 历史记录模块功能测试；

其中，在音频数据处理的过程中，我们针对输入的音频，从音质、音色两个角度动态生成扰动，并使用心理声学模型和 $\mathcal{L}_2$ 范数限制扰动的人耳可感知性。同时为了方便用户使用和理解语音防克隆技术的基本原理和流程，我们设计了简单易用的历史记录模块，自动记录音频保护和合成记录。

另外，为了评估作品在现实中可能遇到的各种实际场景中的有效性，我们除了基本功能测试外，还进行了以下测试：

1. 长语句测试：针对现实生活中长时间通信等场景，我们测试系统在实际场景中对长语音（超过 30s）的防护效果。
2. 不同语言测试：本章中大部分测试，均是针对实际跨国通信场景中最常用的语言英语，进行的测试，故本项测试对国内用户使用普通话进行通话的实际场景评估作品的防护效果。

### 4.3 性能测试结果与分析

#### 4.3.1 针对不同ASR系统的防护性能

在本节中，我们测试了 VoiceGuard 在七个不同 ASR 系统上的防护性能。表 4-2 展示了 VoiceGuard 在不同 ASR 系统上的保护有效性与不可感知性。

表 4-2 针对自适应 ASR 模型的保护有效性和不可感知性测试

| 模型                               | 有效性     |       |         |       | 不可感知性  |       |
|----------------------------------|---------|-------|---------|-------|--------|-------|
|                                  | VITS    |       | GSV     |       |        |       |
|                                  | WER     | SIM   | WER     | SIM   | SNR    | PESQ  |
| Wav2vec2 <sup>[73]</sup>         | 125.299 | 0.245 | 94.812  | 0.284 | 20.470 | 2.324 |
| Whisper-base <sup>[74]</sup>     | 99.598  | 0.144 | 101.082 | 0.088 | 13.362 | 2.053 |
| Whisper-small <sup>[74]</sup>    | 93.996  | 0.163 | 103.518 | 0.138 | 19.0   | 2.077 |
| Whisper-medium <sup>[74]</sup>   | 126.298 | 0.171 | 109.666 | 0.173 | 19.236 | 2.089 |
| Whisper-large-v3 <sup>[74]</sup> | 84.618  | 0.163 | 66.534  | 0.164 | 19.245 | 2.019 |
| Conformer <sup>[74]</sup>        | 105.145 | 0.126 | 81.753  | 0.180 | 12.835 | 1.638 |
| CitriNet <sup>[75]</sup>         | 89.520  | 0.137 | 59.921  | 0.302 | 12.948 | 1.629 |

结果表明，我们的方法为各种 ASR 模型提供了强有力的防护：WER 值始终高于 50%，说明合成音频的可理解性较低，而 SIM 值始终低于 0.25，说明其与原始音频相似度较低。Whisper-large-v3 因其卓越的文本识别准确性、易用性和多语言能力而被广泛应用。VoiceGuard 同样能有效防护 Whisper-large-v3，平均 WER 和 SIM 分别达到 75.576% 和 0.163。

此外，我们的方法在生成扰动的不可察觉性上也优于强基线方法，例如 AntiFake。

#### 4.3.2 多说话人和多语言场景下的防护性能

由于在实际情况中，攻击者可能会使用多说话人或多语言场景下的语音样本。为了解决这一问题，我们在 CMU ARCTIC（多说话人数据集）和 THCHS30（多说话人普通话数据集，针对 Wav2vec2 模型）上验证了该方法。具体来说，我们对 VITS 和 GSV 模型在 CMU ARCTIC 上进行微调，并在 THCHS30 上使用 GSV 模型进行微调。




图 4-1 多说话人和普通话数据集测试

图 4-1(a)展示了多说话人数据集的测试结果（“-o”表示在原始数据集上微调，“-p”表示在受保护数据集上微调）。结果显示，两种模型均能在干净样本上合成高质量音频并保留对应的说话人音色。在对使用 VoiceGuard 保护后的音频上进行微调后，WER 和 SIM 平均分别为 103.021 和 0.144，这表明 VoiceGuard 有效防止了多说话人端到端微调场景下的发音和音色泄露。图 4-1(b)展示了 GSV 模型在普通话数据上的微调效果，其中使用多语言识别模型 Whisper-base 作为攻击目标。

### 4.3.3 有效性和迁移性

为了评估有效性和迁移性，我们使用 VoiceGuard 以无目标和有目标模式保护 LibriTTS 数据集并将 ASR 系统设置为 Wav2vec2，应用于目前 6 种最先进的语音合成模型。

在保护 LibriTTS 数据集后，用户可以将其公开上传到社交平台。敌手可能会未经授权获取这些样本，并利用先进的合成器进行基于微调的语音合成。本节使用 6 种语音合成模型（StyleTTS2、VITS、MBV、GSV、F5-TTS 和 CosyVoice）在微调后生成高质量语音。

语音合成模型在微调后具备语音合成能力。微调模型可以根据说话人 ID 和合成文本生成语音，而零样本克隆模型则需要参考音频和合成文本进行特征提取和克隆。表 4-3 展示了不同语音合成模型在通过不同策略保护的数据集上微调后的实验结果。

表 4-3 VoiceGuard 在不同模型上的有效性和迁移性结果

| 模型        | 指标  | 语音保护算法 |          |          |                     |                     |
|-----------|-----|--------|----------|----------|---------------------|---------------------|
|           |     | 干净样本   | AttackVC | AntiFake | VoiceGuard<br>(非目标) | VoiceGuard<br>(有目标) |
| StyleTTS2 | WER | 10.754 | 9.949    | 11.662   | 61.397              | 115.099             |
|           | SIM | 0.724  | 0.669    | 0.249    | 0.147               | 0.228               |
| GSV       | WER | 10.735 | 15.240   | 34.324   | 70.412              | 74.533              |
|           | SIM | 0.694  | 0.614    | 0.245    | 0.108               | 0.307               |
| F5-TTS    | WER | 9.870  | 12.016   | 10.745   | 30.810              | 133.256             |
|           | SIM | 0.674  | 0.672    | 0.218    | 0.151               | 0.405               |
| CosyVoice | WER | 11.327 | 13.975   | 15.987   | 44.467              | 0.071               |
|           | SIM | 0.702  | 0.688    | 0.232    | 100.279             | 0.370               |
| VITS      | WER | 16.577 | 17.032   | 50.425   | 106.453             | 117.645             |
|           | SIM | 0.709  | 0.672    | 0.261    | 0.092               | 0.296               |
| MBV       | WER | 16.612 | 15.443   | 30.417   | 89.685              | 68.948              |
|           | SIM | 0.710  | 0.665    | 0.227    | 0.118               | 0.291               |

根据表 4-3 可以看出，VoiceGuard 在音色（SIM）和发音（WER）方面相较于基线方法表现出卓越的保护强度。对于微调模型，VoiceGuard 在 WER 上平均提升了 35.104%（非目标模式）和 63.562%（有目标模式），同时 SIM 平均降低了 0.028（非目标模式），表明语音的可懂度和相似度降低。对零样本模型的保护效果更为显著，WER 平均增加了 22.308%（非目标模式）和 91.834%（有目标模式），SIM 平均降低了 0.126（非目标模式）。这表明由 VoiceGuard 保护的音频能够有效保护隐私信息，防止高质量语音合成，并在不同模型间展现出强大的迁移性。

VoiceGuard 的有效性可以归因于两个关键方面。首先，先前的研究表明，对抗样本在隐私保护方面非常有效。其次，VoiceGuard 利用特征编码器提取了比音色更丰富的声学特征集合，同时结合对抗样本来干扰 ASR 系统，使其错误识别文本，并削弱预训练语音合成模型的发音能力。此外，VoiceGuard 在各种主流语音合成模型中表现出强大的迁移性。这是通过集成编码器来增强扰动的通用性实现的。

#### 4.3.4 感知分析

嵌入的扰动不应干扰语音的正常使用。我们引入了心理声学模型以降低扰动的可听度。表 4-4 展示了不同基线方法的模拟感知指标。

表 4-4 语音保护算法的噪声感知结果

| 评价指标 | AttackVC | AntiFake | VoiceGuard<br>(非目标) | VoiceGuard<br>(有目标) |
|------|----------|----------|---------------------|---------------------|
| SNR  | -2.456   | 12.839   | 18.552              | 20.461              |

根据表 4-4，VoiceGuard 的 SNR 高于所有基线方法，表明其噪声比最低且对质量破坏最小。此外，VoiceGuard 在感知效果上优于有效的基线方法，例如 AntiFake。实验表明，VoiceGuard 不会对受保护音频的正常使用造成显著影响。

#### 4.3.5 消融实验结果分析

在消融实验中，我们通过从 VoiceGuard 中逐一移除 $\mathcal{L}_{asr}$ 、 $\mathcal{L}_{fea}$ 以及 $\mathcal{L}_{psy}$ 和 $\mathcal{L}_2$ 这些组件，并评估由此产生的保护有效性。表 4-5 展示了该消融实验的结果。

表 4-5 VoiceGuard 的消融实验

| w/o                                | 有效性     |       |        |       | 不可感知性  |       |
|------------------------------------|---------|-------|--------|-------|--------|-------|
|                                    | VITS    |       | GSV    |       |        |       |
|                                    | WER     | SIM   | WER    | SIM   | SNR    | PESQ  |
| $\mathcal{L}_{psy}\&\mathcal{L}_2$ | 119.242 | 0.101 | 90.436 | 0.081 | 12.942 | 1.544 |
| $\mathcal{L}_{\text{fea}}$         | 101.407 | 0.177 | 65.446 | 0.409 | 15.065 | 1.811 |
| $\mathcal{L}_{\text{asr}}$         | 94.940  | 0.102 | 49.059 | 0.124 | 13.724 | 1.572 |
| VoiceGuard                         | 95.740  | 0.106 | 66.471 | 0.123 | 18.523 | 1.949 |

我们观察到，移除感知优化模块（即 $\mathcal{L}_{psy}$ 和 $\mathcal{L}_2$ ）虽然取得了更好的保护效果，但由于缺乏噪声的感知对齐，显著增加了对原始音频的感知破坏，导致信噪比（SNR）低至 12.942。为了直接检验 $\mathcal{L}_{asr}$ 和 $\mathcal{L}_{fea}$ 的效果，我们分别单独优化每一项。当移除 $\mathcal{L}_{fea}$ 仅保留 $\mathcal{L}_{asr}$ 时，在 GSV 模型上的 SIM 值相对较高，为 0.409，表明声纹信息存在显著

泄露。相反，当移除 $\mathcal{L}_{asr}$ 仅保留 $\mathcal{L}_{fea}$ 时，对文本-发音对齐的破坏减弱，在 GSV 模型上的 WER 下降至 49.059%。当所有三个组件都存在时，它们共同在发音和音色层面提供有效保护，同时保持了更好的扰动不可感知性。

#### 4.3.6 鲁棒性测试结果分析

在现实世界场景中，强大的攻击者可能会对获取的数据集进行特定修改，并且可能采用对抗性技术来提高合成质量。在本部分，我们遵循文献<sup>[76]</sup>的方法，针对扰动移除和高级数据增强技术进行鲁棒性测试。此外，我们评估了 VoiceGuard 在现实世界中的有效性和鲁棒性。

高质量的语音合成通常需要没有可听扰动的高质量输入音频<sup>[76]</sup>。因此，攻击者可能会利用扰动移除技术来提高训练样本的质量，并在用户上传前削弱其可能采用的未知保护策略。

我们参考使用一种高效的降噪技术<sup>[76]</sup>，即谱门限（Spectral Gating, SG），对每个受保护的音频样本进行降噪。该实验在两个模型（即 VITS 和 GSV）上进行。在 VITS 模型上，WER 和 SIM 分别为 51.005%和 0.224。而在 GSV 模型上，WER 和 SIM 分别为 31.958%和 0.251。这表明，即使移除了可听噪声，VoiceGuard 仍然能够保护说话人隐私，特别是在说话人相似度层面，这两个模型的平均 SIM 值仅为 0.237。此外，在 VITS 模型上的 WER 超过了 50%，有效破坏了发音。

数据增强用于改变嵌入扰动的特定结构，从而降低其效果。我们考虑三类数据增强技术：

##### 1. 对抗性防御器（Adversarial Defender）

Hussain 等人<sup>[77]</sup>发现，在音频领域，某些对抗性防御方法可以有效破坏对抗性音频样本。这些对抗性技术包括：下采样和上采样（RS），梅尔谱图提取和反转（Mel）、量化-反量化（Q-D）以及滤波（Filtering）。

##### 2. 音频处理器（Audio Processor）

我们考虑语音处理技术来模拟现实世界的操作，包括速度调整（Speed）、添加高斯噪声（Gaussian）、时间掩蔽（TiM）、音高偏移（PS）、MP3 压缩和 Tanh 失真（Tanh）。

##### 3. 滤波器（Filters）

滤波技术通常用于改变扰动。我们考虑三种滤波技术：带通滤波器（BPF）、低通滤波器（LPF）和高通滤波器（HPF）。

表 4-6 显示了数据增强的结果。我们观察到 Mel 技术显著提高了合成音频的可懂度，在 VITS 和 GSV 模型上的 WER 值分别下降了 39.194%和 19.825%。然而，SIM 值仍然很高。尽管数据增强可以干扰扰动并降低其保护效果，但嵌入的扰动仍然存在，并且转换音频本身会降低其质量，例如 Mel 和滤波器技术。

表 4-6 数据增强和防御方法下的结果

| 模型                     |           | VITS    |       | GSV    |        |
|------------------------|-----------|---------|-------|--------|--------|
| 评价指标                   |           | WER     | SIM   | WER    | SIM    |
| w/o                    |           | 96.735  | 0.113 | 69.148 | 0.074  |
| 对抗性防御器 <sup>[77]</sup> | Resample  | 94.827  | 0.115 | 55.035 | 0.195  |
|                        | Mel       | 55.633  | 0.122 | 35.210 | 0.158  |
|                        | Q-D       | 103.247 | 0.082 | 75.011 | 0.117  |
|                        | Filtering | 93.552  | 0.128 | 57.497 | 0.147  |
| 音频处理器                  | Speed     | 84.101  | 0.080 | 77.642 | 0.044  |
|                        | Gaussian  | 84.881  | 0.163 | 44.232 | 0.128  |
|                        | TiM       | 95.654  | 0.098 | 77.165 | 0.109  |
|                        | PS        | 91.796  | 0.099 | 68.607 | 0.049  |
|                        | MP3       | 82.298  | 0.125 | 41.903 | 0.154  |
|                        | Tanh      | 95.441  | 0.143 | 71.446 | 0.126  |
| 滤波器                    | BPF       | 97.258  | 0.136 | 83.050 | -0.046 |
|                        | LPF       | 95.553  | 0.118 | 52.882 | 0.135  |
|                        | HPF       | 136.552 | 0.045 | 48.036 | 0.229  |

在用户上传经过 VoiceGuard 保护的音频后，攻击者可能会使用各种类型的麦克风来录制和收集在现实世界中播放的音频，以进行语音克隆。为了验证 VoiceGuard 在空中传输场景中的鲁棒性，我们采用不同的扬声器来播放音频作为说话人端，并使用不同的麦克风来录制音频作为攻击者端。

我们在一个安静的环境中进行实验，背景噪声平均为 22 dBA（通过取 10 秒的平均值测量）。我们使用联想笔记本电脑的内置扬声器播放音频，并使用 VIVO 和小米

手机（放置在距离扬声器约一米处）录制音频来模拟攻击者。在每次测试中，我们播放 10 个音频样本，并确保扬声器的响度平均为 46 dBA。最后，对于录制的音频，我们采用 GSV 模型进行微调和克隆，因为它具有出色的少样本克隆能力<sup>[65]</sup>。

未经扰动的原始音频在录制后的合成结果为 WER 值为 16.837% 和 SIM 值为 0.485，说话人一致性比较高。而经过 VoiceGuard 保护的音频，其平均 WER 和 SIM 分别为 72.615% 和 0.068（见图 4-2）




图 4-2 在真实世界中的鲁棒性测试

实验结果表明，在现实世界场景中能出色地保护语音音色和发音。此外，当我们将扬声器替换为移动设备（小米手机）并使用 VIVO 手机作为录制设备时，保护效果仍然很高，该实验证明了 VoiceGuard 在处理数据增强方面的有效性。

## 4.4 应用测试结果与分析

### 4.4.1 基本功能测试

首先，需要用户通过上传文件或在网页端录入语音的方法上传语音文件，如图 4-3 和图 4-4 所示。



图 4-3 本地音频上传



图 4-4 实时音频录制

上传音频后，可以选择对原始音频进行保护，点击保护按钮可以将音频上传到服务器，调用对抗扰动生成算法，生成保护后的音频并回传前端，如图 4-5 所示。




图 4-5 音频保护功能

经过以上保护模块后，还可以选择通过模拟攻击者可能进行的语音合成方法来展示保护效果。用户可以在几种常见的语音合成方法中做出选择，设置目标音频，随后点击“语音合成”按钮，就可以分别使用原始语音和目标语音作为参考音频进行端到端的语音合成，如图 4-6 所示。




图 4-6 保护前后语音克隆效果对比

## 4.4.2 历史记录功能测试

本系统中设计的历史记录模块位于网页的下方，向用户直观地展示了曾经保护和克隆过的音频记录，如图 4-7 所示。



图 4-7 历史记录功能

直接点击历史记录状态栏中的记录，就能直接加载响应的音频、ASR 转录文本和波形图到上方的音频展示框，如图 4-8 所示。



图 4-8 历史记录加载

### 4.4.3 长语音测试

在前述实验的训练和测试数据集中，大多数音频文件的长度都比较短，大多数不超过 30s。而在现实生活中的实时语音和视频发布场景中有时音频文件长度会相对较长，在通信场景中也会遇到比较长的音频数据流情况，因此我们还进行了长语音测试。在网页端现场录制一段长度约为一分钟的视频，随后先后进行保护和克隆，结果如图 4-9 所示。



图 4-9 长语音保护与合成测试

#### 4.4.4 中文音频测试

在本节中，我们对汉语进行了测试，结果如图 4-10 所示。结果显示，四段音频的转录均能显示出正确语义，而添加防护后的音频转录结果与原始转录文本有较大差异，且没有相似的语义。由此说明，本系统的防护对不同的语言仍能显示出较好的有效性，对汉语普通话也能显示出不明显弱于英语的防御效果。

上传或录制音频

上传音频文件

开始录制

停止录制

保护

“成功”克隆语音

原始音频 A

0:00 / 0:19

ASR识别结果:

他占有，挑选。看见鱼翅，并不就抛在路上以显其“平民化”，只要有养料，也和朋友们像萝卜白菜一样的吃掉，只不用它来宴大宾；看见鸦片，也不当众摔在茅厕里，以见其彻底革命，只送到药房里去，以供治病之用，却不弄“出售存膏，售完即止”的玄虚。

保护音频 B

0:00 / 0:19

ASR识别结果:

ja shisoo hi won as o hime on tons ta wo scarde see you the en sir ra intruder ye aint fan holon bak wisy to a my woman that yo shal dak io me a e wo short yet basy on daship ani hope shel ine you now ho oman a

语音克隆设置

选择TTS方法: StyleTTS

目标音频文本: 总之，我们要拿来。我们要或使用，或存放

执行语音克隆

原始克隆音频 C

0:00 / 0:05

ASR识别结果:

总之，我们要拿来。我们要或使用，或存放，或毁灭。那么，主人是新主人，宅子也就成为新宅子。

保护后克隆音频 D

0:00 / 0:06

ASR识别结果:

ha i din her you all i gate a a ye sha woman the ja shisoo hi won as o hime on tons ta wo scarde see you the en sir ra intruder ye aint fan holon bak wisy to a my woman that yo shal dak io me a e wo short yet

图 4-10 汉语音频保护与合成测试

## 第五章 创新性说明

针对当前生成式人工智能浪潮下日益严峻的语音深度伪造风险，本作品深入分析了语音防克隆保护的现有技术研究的进展以及潜在的解决方案。在此基础上，作品对研究方法进行了创新性的拓展和深化，设计了本系统的架构方案和实施策略，创新性地构建了一个面向“端到端微调”攻击范式的主动防御框架 VoiceGuard。

VoiceGuard 精准地将防御目标锁定在攻击者通过微调预训练模型以获取更高克隆质量的场景，并将数据毒化理念与多维度对抗攻击相结合，从数据源头构建防御壁垒，有效应对更具现实威胁的端到端微调攻击场景。本作品不仅在技术上实现了创新，更在研究方法上进行了重要的探索和实践，为未来防克隆语音保护技术的发展提供了新的思路 and 方向。本作品的主要创新性如下：

**1. 面向“端到端微调”场景的高鲁棒性主动防御框架VoiceGuard。**现有语音防克隆技术（如AttackVC、VSMask、AntiFake）主要聚焦于“零样本克隆”场景，其防御目标是阻止模型在推理阶段直接模仿目标音色。然而，现实中攻击者更倾向于通过微调预训练模型来获得更高保真度的克隆效果，且其文本输入往往依赖于自动语音识别（ASR）系统，形成“音频输入-ASR转录-模型微调-音频输出”的端到端攻击链。本作品系统性地将防御目标对准这一更具挑战性的攻击范式，设计了VoiceGuard框架，旨在通过毒化用于微调的原始音频数据，从模型训练的源头破坏其学习过程，从而提供前置性、根本性的保护。通过编码器集成和精心设计的损失函数，VoiceGuard在多个先进的开源和商业级语音合成模型上均展现出卓越的防御效果，无需针对特定模型进行重新优化，具备极强的通用性和鲁棒性。

**2. “音色-发音”双维度协同毒化机制，实现对克隆语音的联合降质。**区别于以往仅针对音色特征进行扰动的单点防御，VoiceGuard创新性地构建了双路协同攻击目标函数，从两个核心维度同时破坏克隆效果，实现了对合成语音质量的联合降质。在音色维度，VoiceGuard摒弃了单一特征提取器的局限，创新性地集成了多个音色编码器并融合梅尔频率倒谱系数（MFCC）等声学特征，构建了更具迁移性和泛化能力的特征目标函数，支持无目标（最大化与原音色距离）和有目标（引导至特征差异最大的目标音色）两种保护模式，从而在广泛的语音合成模型上实现对说话人身份特征的

有效混淆。在发音维度，本作品创造性地引入了针对ASR系统的对抗样本攻击，通过诱导其输出错误的转录文本，从根本上破坏了语音合成模型赖以学习的“文本-音频”对齐关系，使得模型即使部分提取了音色信息，也无法根据正确的指令重构出发音内容，这一策略巧妙地将ASR系统的脆弱性转化为防御的有力武器。

**3. 引入心理声学模型与范数约束，实现高保真度的隐蔽性保护。**为了确保防克隆保护措施在实际应用中的强隐蔽性与高可用性，本作品在扰动生成过程中深度融合了先进的感知优化技术。利用人耳听觉的“掩蔽效应”，VoiceGuard将对抗性噪声精准地嵌入到人耳感知不敏感的频域能量区域，并辅以与人类听觉感知相关性最佳的L2范数对扰动幅度进行约束，实现了高保真度的感知优化，科学地平衡了扰动强度与不可感知性之间的权衡，在保持强大防御效力的同时，最大程度地维持了原始音频的听觉自然度，确保保护后的音频在信噪比（SNR）和语音质量感知评估（PESQ）等指标上表现优异，满足实际应用中对音频质量的高要求。

## 第六章 总结

语音合成得益于其出色的声音复刻和音频生成能力，近年来备受大家关注。本作品关注于未经授权或用于非法途径的语音合成，例如电信诈骗、声纹隐私窃取等。针对前人研究的不足，本作品聚焦于语音防克隆技术，关注目前一种端到端微调的语音合成技术，其通过语音识别模型得到音频的文本用于训练，从而降低人工标注所带来的时间和人力开销。

针对这一场景，本作品提出一种名为VoiceGuard的语音防克隆保护系统，旨在保护用户关键语音数据的隐私安全。本作品将对抗扰动技术和数据毒化技术应用于语音隐私保护，在数据保护层面分为音色和发音保护，使得语音数据能够在多种不同的基于端到端微调的语音合成系统上展现出高效的防御性能，以满足实际场景中用户对个人敏感声纹信息的保护需求。此外，作品还采用了心理声学模型和范数约束降低人耳对对抗扰动的感知，提高保护音频的保真度。具体而言，本作品的贡献主要体现在以下几个方面：

### 1. 提出了一种针对端到端微调的语音合成系统的语音防克隆系统VoiceGuard。

针对当前基于端到端微调架构的语音克隆技术所带来的新型隐私威胁，即攻击者仅凭极少量语音样本即可实现高保真语音伪造，进而引发身份冒用、社会工程攻击与深度伪造音频等安全风险，本作品提出了针对端到端微调的语音防克隆系统VoiceGuard。其从语音数据源头出发，结合对抗样本、音色-发音联合扰动机制与数据毒化策略，精准干扰微调过程中模型对目标声纹特征的拟合。同时VoiceGuard的设计考虑到了现代通信的实时性和安全性需求，使其能够在不显著影响用户体验的前提下，为语音通信提供强有力的保护。本系统精简易用，其对抗扰动生成机制简化了防御过程，能够快速适应不同的语音样本和ASR系统，且易于集成到现有的通信系统中。

### 2. 融合音色保护和发音保护在内的多项技术显著提高系统对语音防克隆保护的性

能。在音色维度，通过集成多个音色编码器并融合MFCC等声学特征，构建了更具迁移性的特征目标函数，支持无目标与有目标两种保护模式，有效混淆说话人身份特征。在发音维度，创造性地利用针对ASR系统的对抗样本攻击，诱导其输出错误转录文本，从而破坏语音合成模型赖以学习的“文本-音频”对齐关系，使克隆语音在内

容上失效。为确保防御措施的实用性，本作品进一步引入了基于心理声学模型的感知优化和L2范数约束，将对抗噪声嵌入人耳不敏感的频域，实现了防御效力与听觉自然度的科学平衡。这种方法不仅提升了扰动的迁移性，也确保了高音频质量，满足了实时通信场景对音频质量的要求。

**3. 针对系统的技术性能与实际应用开展了广泛的测试与评估以保证系统的有效性。**在第四章中，本作品针对VoiceGuard的有效性在多个主流开源及商业模型上展开一系列测试。性能测试实验结果表明，VoiceGuard在多种最先进的语音合成模型上具有广泛的迁移性和鲁棒性，能够在面对各种自适应攻击时提供高效的防护。此外，VoiceGuard还具备实时保护能力，可以在现场演讲或在线直播等实际场景中快速生成针对特定说话人的扰动，确保语音的安全性和隐私性。这一框架在端到端微调的语音合成场景下展现了卓越的性能，为个人语音数据的安全提供了强有力的保障。同时，通过实际应用测试，进一步验证了系统在真实环境下的表现，确保了从技术到应用实践的成功转化，为未来的进一步应用奠定了基础。

这些成果展示出本作品在防克隆语音保护方面上的高效性和鲁棒性。总体来说，本作品为解决语音数据保护问题提供了一个创新的视角，实现了基于数据毒化的高鲁棒性防克隆语音保护系统，可以在各种实际场景下有效保护用户的语音隐私安全。

## 参考文献

- [1] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [2] Li Z, Liu F, Yang W, et al. A survey of convolutional neural networks: analysis, applications, and prospects[J]. IEEE transactions on neural networks and learning systems, 2021, 33(12): 6999-7019.
- [3] Li Z, Liu F, Yang W, et al. A survey of convolutional neural networks: analysis, applications, and prospects[J]. IEEE transactions on neural networks and learning systems, 2021, 33(12): 6999-7019.
- [4] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [5] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [6] Kaplan J, McCandlish S, Henighan T, et al. Scaling laws for neural language models[J]. arXiv preprint arXiv:2001.08361, 2020.
- [7] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [8] Tan X, Qin T, Soong F, et al. A survey on neural speech synthesis[J]. arXiv preprint arXiv:2106.15561, 2021.
- [9] Kim J, Kong J, Son J. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech[C]//International Conference on Machine Learning. PMLR, 2021: 5530-5540.
- [10] Li Y A, Han C, Raghavan V, et al. Styletts 2: Towards human-level text-to-speech through style diffusion and adversarial training with large speech language models[J]. Advances in Neural Information Processing Systems, 2023, 36: 19594-19621.

- [11]Liao S, Wang Y, Li T, et al. Fish-speech: Leveraging large language models for advanced multilingual text-to-speech synthesis[J]. arXiv preprint arXiv:2411.01156, 2024.
- [12]Jiang Z, Ren Y, Li R, et al. Megatts 3: Sparse alignment enhanced latent diffusion transformer for zero-shot speech synthesis[J]. arXiv preprint arXiv:2502.18924, 2025.
- [13][https://www.thepaper.cn/newsDetail\\_forward\\_26284950](https://www.thepaper.cn/newsDetail_forward_26284950)
- [14][https://www.sohu.com/a/933582607\\_121141910](https://www.sohu.com/a/933582607_121141910)
- [15]<https://blog.securemymind.com/security-risks-and-countermeasures-of-voice-cloning.html>
- [16]<https://www.secrss.com/articles/63416>
- [17][https://www.fortunechina.com/magazine/c/2024-01/15/content\\_444937.htm](https://www.fortunechina.com/magazine/c/2024-01/15/content_444937.htm)
- [18][https://www.spp.gov.cn/spp/zdgz/202308/t20230823\\_625773.shtml](https://www.spp.gov.cn/spp/zdgz/202308/t20230823_625773.shtml)
- [19]<https://www.faxianlaw.com/cn/details/1289/45e462b8ad396f37>
- [20]<https://www.bbc.com/zhongwen/trad/world-57802827>
- [21]Klatt D H, Klatt L C. Analysis, synthesis, and perception of voice quality variations among female and male talkers[J]. the Journal of the Acoustical Society of America, 1990, 87(2): 820-857.
- [22]Tokuda K, Zen H, Black A W. An HMM-based speech synthesis system applied to English[C]//IEEE speech synthesis workshop. Santa Monica: IEEE, 2002: 227-230.
- [23]Tokuda K, Zen H, Black A W. An HMM-based speech synthesis system applied to English[C]//IEEE speech synthesis workshop. Santa Monica: IEEE, 2002: 227-230.
- [24]Wang Y, Skerry-Ryan R J, Stanton D, et al. Tacotron: Towards end-to-end speech synthesis[J]. arXiv preprint arXiv:1703.10135, 2017.
- [25]Shen J, Pang R, Weiss R J, et al. Natural tts synthesis by conditioning wavenet on mel spectrogram predictions[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 4779-4783.
- [26]Ren Y, Ruan Y, Tan X, et al. FastSpeech: Fast, robust and controllable text to speech[J]. Advances in neural information processing systems, 2019, 32.
- [27]Ren Y, Hu C, Tan X, et al. FastSpeech 2: Fast and high-quality end-to-end text to speech[J]. arXiv preprint arXiv:2006.04558, 2020.

- [28]Kong J, Kim J, Bae J. Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis[J]. Advances in neural information processing systems, 2020, 33: 17022-17033.
- [29]Xie T, Rong Y, Zhang P, et al. Towards controllable speech synthesis in the era of large language models: A survey[J]. arXiv preprint arXiv:2412.06602, 2024.
- [30]Du Z, Chen Q, Zhang S, et al. Cosyvoice: A scalable multilingual zero-shot text-to-speech synthesizer based on supervised semantic tokens[J]. arXiv preprint arXiv:2407.05407, 2024.
- [31]Huang C, Lin Y Y, Lee H, et al. Defending your voice: Adversarial attack on voice conversion[C]//2021 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2021: 552-559.
- [32]Wang Y, Guo H, Wang G, et al. Vsmask: Defending against voice synthesis attack via real-time predictive perturbation[C]//Proceedings of the 16th ACM Conference on Security and Privacy in Wireless and Mobile Networks. 2023: 239-250.
- [33]Yu Z, Zhai S, Zhang N. Antifake: Using adversarial audio to prevent unauthorized speech synthesis[C]//Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security. 2023: 460-474.
- [34]Zakaria M, Mabrouka A S, Sarhan S. Artificial neural network: a brief overview[J]. neural networks, 2014, 1: 2.
- [35]LeCun Y, Bengio Y. Convolutional networks for images, speech, and time series[J]. The handbook of brain theory and neural networks, 1998.
- [36]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [37]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [38]Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [39]Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by

- generative pre-training[J]. 2018.
- [40] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [41] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [42] Yang A, Li A, Yang B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.
- [43] Dong Q, Li L, Dai D, et al. A survey on in-context learning[J]. arXiv preprint arXiv:2301.00234, 2022.
- [44] Klatt D H. Software for a cascade/parallel formant synthesizer[J]. the Journal of the Acoustical Society of America, 1980, 67(3): 971-995.
- [45] Hunt A J, Black A W. Unit selection in a concatenative speech synthesis system using a large speech database[C]//1996 IEEE international conference on acoustics, speech, and signal processing conference proceedings. IEEE, 1996, 1: 373-376.
- [46] Zen H, Tokuda K, Black A W. Statistical parametric speech synthesis[J]. speech communication, 2009, 51(11): 1039-1064.
- [47] Nose T, Yamagishi J, Masuko T, et al. A style control technique for HMM-based expressive speech synthesis[J]. IEICE TRANSACTIONS on Information and Systems, 2007, 90(9): 1406-1413.
- [48] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [49] Kong Z, Ping W, Huang J, et al. Diffwave: A versatile diffusion model for audio synthesis[J]. arXiv preprint arXiv:2009.09761, 2020.
- [50] Popov V, Vovk I, Gogoryan V, et al. Grad-tts: A diffusion probabilistic model for text-to-speech[C]//International conference on machine learning. PMLR, 2021: 8599-8608.
- [51] Casanova E, Davis K, Gölge E, et al. Xtts: a massively multilingual zero-shot text-to-speech model[J]. arXiv preprint arXiv:2406.04904, 2024.
- [52] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[J]. arXiv preprint arXiv:1312.6199, 2013.

- [53]Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv:1412.6572, 2014.
- [54]Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083, 2017.
- [55]Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE Symposium on Security and Privacy (SP). Ieee, 2017: 39-57.
- [56]Wierstra D, Schaul T, Glasmachers T, et al. Natural evolution strategies[J]. arXiv preprint arXiv:1106.4487, 2011.
- [57]Xu H, Ma Y, Liu H C, et al. Adversarial attacks and defenses in images, graphs and text: A review[J]. International journal of automation and computing, 2020, 17(2): 151-178.
- [58]Zeng Y, Qiu H, Memmi G, et al. A data augmentation-based defense method against adversarial attacks in neural networks[C]//International Conference on Algorithms and Architectures for Parallel Processing. Cham: Springer International Publishing, 2020: 274-289.
- [59]Zheng H, Zhang Z, Gu J, et al. Efficient adversarial training with transferable adversarial examples[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 1181-1190.
- [60]Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083, 2017.
- [61]Fan J, Yan Q, Li M, et al. A survey on data poisoning attacks and defenses[C]//2022 7th IEEE International Conference on Data Science in Cyberspace (DSC). IEEE, 2022: 48-55.
- [62]Gajbhiye S, Singh P, Gupta S. Data poisoning attack by label flipping on splitfed learning[C]//International Conference on Recent Trends in Image Processing and Pattern Recognition. Cham: Springer Nature Switzerland, 2022: 391-405.
- [63]Shafahi A, Huang W R, Najibi M, et al. Poison frogs! targeted clean-label poisoning attacks on neural networks[J]. Advances in neural information processing systems, 2018, 31.
- [64]Huang H, Ma X, Erfani S M, et al. Unlearnable examples: Making personal data

- unexploitable[J]. arXiv preprint arXiv:2101.04898, 2021.
- [65] RVC-Boss. Gpt-sovits. <https://github.com/RVC-Boss/GPT-SoVITS>, 2024.
- [66] Radford A, Kim J W, Xu T, et al. Robust speech recognition via large-scale weak supervision[C]//International conference on machine learning. PMLR, 2023: 28492-28518.
- [67] Fowl L, Goldblum M, Chiang P, et al. Adversarial examples make strong poisons[J]. Advances in Neural Information Processing Systems, 2021, 34: 30339-30351.
- [68] Kim J, Kim S, Kong J, et al. Glow-tts: A generative flow for text-to-speech via monotonic alignment search[J]. Advances in Neural Information Processing Systems, 2020, 33: 8067-8077.
- [69] Zwicker E, Fastl H. Psychoacoustics: Facts and models[M]. Springer Science & Business Media, 2013.
- [70] Meerza S I A, Sun L, Liu J. Harmonycloak: Making music unlearnable for generative ai[C]//2025 IEEE Symposium on Security and Privacy (SP). IEEE, 2025: 430-448.
- [71] Duan R, Qu Z, Zhao S, et al. Perception-aware attack: Creating adversarial music via reverseengineering human perception[C]//Proceedings of the 2022 ACM SIGSAC conference on computer and communications security. 2022: 905-919.
- [72] Desplanques B, Thienpondt J, Demuynck K. Ecapa-tdnn: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification[J]. arXiv preprint arXiv:2005.07143, 2020.
- [73] Baevski A, Zhou Y, Mohamed A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations[J]. Advances in neural information processing systems, 2020, 33: 12449-12460.
- [74] Radford A, Kim J W, Xu T, et al. Robust speech recognition via large-scale weak supervision[C]//International conference on machine learning. PMLR, 2023: 28492-28518.
- [75] Gulati A, Qin J, Chiu C C, et al. Conformer: Convolution-augmented transformer for speech recognition[J]. arXiv preprint arXiv:2005.08100, 2020.
- [76] Feng S, Kudina O, Halpern B M, et al. Quantifying bias in automatic speech recognition[J]. arXiv preprint arXiv:2103.15122, 2021.

- [77]Zhang Z, Wang D, Yang Q, et al. SafeSpeech: Robust and Universal Voice Protection Against Malicious Speech Synthesis[J]. arXiv preprint arXiv:2504.09839, 2025.
- [78]Hussain S, Neekhara P, Dubnov S, et al. {WaveGuard}: Understanding and mitigating audio adversarial examples[C]//30th USENIX security symposium (USENIX Security 21). 2021: 2273-2290.